OpenRSI-Calibrator：面向光学遥感影像的开放词汇目标检测与可靠语义校准

竞赛作品申报书

作者、单位与指导教师：待填写

2026 年 10 月

摘要

光学遥感影像解译正在从“在固定类别表中找目标”转向“按用户提出的词语找目标”。灾后评估、自然资源巡查和港口监测经常出现训练类别之外的查询对象，而主流遥感检测基准只覆盖 15 至 37 个类别，重新标注与训练的周期难以跟上业务需求。通用开放词汇检测器以图文对齐取代固定分类头，但它们主要在自然图像上训练；俯视视角、极端尺度差异、任意方向和密集排列使其在遥感影像中的定位与分类同时退化，并且输出分数往往不能解释为可靠的概率。

本作品提出 OpenRSI-Calibrator，一套面向光学遥感影像的开放词汇检测与可靠语义校准方案。方案由三部分组成：其一，以“对象—属性—场景”三层原型和负向描述建立遥感域词汇原型，缓解自然语言与俯视影像之间的语义偏移；其二，以多尺度重叠切片与水平框、旋转框协同生成候选，并在整图坐标下按几何与语义一致性分层融合；其三，将候选分数分解为语义匹配、几何质量、背景对照和查询稳定性四项证据，在独立校准集上做事后校准，并据此给出接受、复核、拒识三态决策。

本文围绕四项可证伪假设设计实验：域内原型能否提高新类召回并在跨区域测试中保持收益，旋转候选协同是否主要改善小目标与细长目标，校准与背景对照能否降低高置信误报而不过度牺牲召回，以及证据卡能否缩短人工复核时间。实验采用 DIOR、DOTA 与 FAIR1M 构建基础类与新类划分，对照 Grounding DINO、YOLO-World 等通用路线和 CastDet、LAE-DINO、OpenRSD 等遥感路线，并预先规定统计方法、消融顺序和推翻假设的结果。本文中所有实验结果均为计划或待实测项，未运行的实验不报告数值。

关键词：开放词汇目标检测；光学遥感影像；视觉—语言模型；旋转框检测；置信度校准

Abstract

Optical remote-sensing interpretation is shifting from searching a fixed label set to answering free-form queries. Public remote-sensing detection benchmarks cover only 15 to 37 categories, while disaster assessment, resource inspection and port monitoring routinely ask for objects outside those lists. General open-vocabulary detectors replace the fixed classifier with image–text alignment, but they are trained mainly on natural images; overhead viewpoints, extreme scale variation, arbitrary orientation and dense layouts degrade both localization and classification, and their scores are rarely calibrated probabilities.

We propose OpenRSI-Calibrator, an open-vocabulary detection and reliability-calibration design for optical remote-sensing imagery. It builds object–attribute–scene prototypes with negative descriptions to reduce the semantic gap between language and overhead imagery; generates horizontal and oriented candidates from overlapping multi-scale tiles and fuses them in global coordinates; and decomposes each score into semantic, geometric, background-contrast and query-stability evidence, calibrated post hoc on a held-out split to support accept, review and reject decisions.

Four falsifiable hypotheses organize the evaluation on base/novel splits derived from DIOR, DOTA and FAIR1M, against general detectors such as Grounding DINO and YOLO-World and remote-sensing methods such as CastDet, LAE-DINO and OpenRSD. Statistical procedures, ablation order and the outcomes that would refute each hypothesis are fixed in advance. No experimental result is reported in this proposal; every metric is marked as planned.

Keywords: open-vocabulary object detection; optical remote sensing; vision–language model; oriented object detection; confidence calibration

目　录

摘要 I

Abstract II

第 1 章 绪论 1

1.1 遥感解译从固定类别走向开放查询 1

1.2 选择光学遥感目标检测作为研究子领域的理由 2

1.3 共性挑战及其对决策的影响 2

1.4 研究问题链与本文工作边界 3

1.5 本文结构 4

第 2 章 相关研究与研究缺口 6

2.1 遥感检测基准与旋转框检测 6

2.2 通用开放词汇检测的四条技术路线 7

2.3 遥感视觉—语言表示的进展与边界 9

2.4 遥感开放词汇检测的代表性工作 9

2.5 置信度校准与开放词汇评测中的负面证据 11

2.6 尚未解决的关键问题 11

第 3 章 研究设计与可证伪假设 13

3.1 任务定义与符号 13

3.2 设计原则与取舍依据 14

3.3 四项研究假设及其否证条件 15

3.4 研究边界与不作承诺的部分 16

第 4 章 OpenRSI-Calibrator 方法 18

4.1 总体框架 18

4.2 遥感域词汇原型适配 19

4.2.1 三层原型的构成 19
4.2.2 负向描述与背景原型 19
4.2.3 投影层的训练目标 20
4.2.4 原型来源与版本管理 21
4.3 多尺度切片与旋转候选协同 21
4.3.1 多尺度重叠切片 21
4.3.2 水平框与旋转框的协同 22
4.4 跨切片融合与冲突记录 23
4.5 可靠性校准与三态决策 23
4.5.1 查询稳定性分数 23
4.5.2 校准方法 24
4.5.3 三态决策规则 24
4.5.4 拒识的解释 25
4.6 计算复杂度与部署成本 25
第 5 章 实验方案 26
5.1 实验总览 26
5.2 数据集、类别划分与泄漏控制 26
5.2.1 基础类与新类划分 26
5.2.2 信息泄漏的来源与控制 27
5.3 对照方法与公平比较规则 28
5.4 评价指标及其能支持的结论 29
5.5 主实验设计 30
5.6 消融实验 32
5.7 鲁棒性与跨域测试 32
5.8 统计不确定性与多重比较 33

5.9 案例研究：同义查询下的一致性 34
5.10 失败分析与停止规则 35
第 6 章 系统实现与应用场景 37
6.1 系统组成与数据流 37
6.2 证据卡与人工复核 37
6.3 应用场景与用户任务 38
6.4 部署形态与成本边界 39
6.5 风险、许可与数据治理 40
第 7 章 结论与研究局限 41
7.1 主要结论 41
7.2 研究局限 41
7.3 后续工作 41
参考文献 42

第 1 章 绪论

1.1 遥感解译从固定类别走向开放查询

光学遥感影像目标检测的主流研究范式，是在一个预先定义的类别集合上训练检测器，并用同一集合上的平均精度（average precision，AP；各类别 AP 的均值记为 mAP）衡量进展。这一范式由大规模公开基准推动形成：DOTA 收集 2806 幅约 4000×4000 像素的航空影像，用任意四边形标注了 15 个类别共 188282 个实例[1]；DIOR 包含 23463 幅影像、20 个类别和 192472 个实例，并强调尺度变化、类间相似和类内差异[2]；FAIR1M 将实例规模提高到 100 万以上，类别细化为 5 个大类、37 个子类[3]；DOTA-v2.0 进一步扩展到 11268 幅影像、18 个类别和 1793658 个实例[4]。这些数据集解决了“有没有足够标注”的问题，但它们共享一个前提：使用者关心的对象在数据集发布时已经确定。

这一前提在业务场景中经常不成立。灾后评估需要寻找“受损码头”“临时安置帐篷”“阻断道路的倒塌物”，自然资源巡查需要发现“新增采砂场”“违规堆土”，港口运营需要区分“集装箱船”与“散货船”。这些查询对象要么不在公开类别表中，要么只以更粗的上位类出现。若沿用固定类别范式，每出现一个新需求就要经历样本收集、边界框标注、质量检查、模型训练和重新验收五个环节，其中标注环节需要具备遥感解译经验的人员参与，难以临时扩充人力。许多遥感任务的价值集中在事件发生后的早期，例如灾后道路是否可通行的判断需要在救援调度之前给出，固定类别范式的响应周期与这类需求并不匹配。

开放词汇目标检测为这一矛盾提供了另一种思路：用文本编码器把类别名称或描述映射到与视觉区域相同的嵌入空间，使检测器在推理时接受训练集之外的类别词。这一方向在自然图像上已形成多条成熟路线，其共同前提是大规模图文预训练提供了足够宽的视觉—语言对应关系。问题在于，这种对应关系主要来自地面视角的互联网图像，遥感影像中的俯视形态、尺度和上下文与之差异显著，通用模型能否直接迁移，是本作品首先需要回答的问题。

开放词汇并不意味着“任何词都能查”。即使在自然图像上，开放词汇检测器对新类的精度通常也明显低于对训练类的精度，而且对查询措辞敏感。对于遥感使用者而言，比“能否接受新词”更关键的问题是：系统给出的新类结果有多大把握，哪些结果可以直接使用，哪些需要人工确认。若这一问题得不到回答，开放词汇能力只会把更多未经筛选的候选推给解译人员，反而增加负担。本作品因此把“可靠性”与“开放性”放在同等重要的位置。

1.2 选择光学遥感目标检测作为研究子领域的理由

开放词汇能力可以落在多种遥感任务上，包括场景分类、图文检索、语义分割和目标检测。本作品选择光学遥感影像中的目标检测，理由有三。第一，检测直接回答“在哪里、是什么”，是灾后评估、资产盘点和变化巡查等任务中人工复核的基本单元；分类和检索只给出整幅影像或影像块的判断，无法支撑逐目标的处置。第二，光学影像拥有最成熟的公开检测基准和旋转框标注体系，可以在不新建大规模数据集的前提下构造基础类与新类划分，使研究结论可复现、可比较。第三，检测任务同时暴露语义对齐、几何定位和置信度三类问题，比分类任务更能检验开放词汇方法在遥感域中的真实短板。

合成孔径雷达、多光谱和高光谱影像同样存在开放类别需求，但它们的成像机理与自然图像差异更大，现有图文预训练资源极少，研究风险显著高于光学影像。本文将其列为后续扩展方向，不在本阶段的实验和结论中涉及。视频卫星与时序变化检测也被排除在主实验之外，因为时间维度会引入配准误差和变化定义问题，与本文要检验的语义与校准机制相互混杂。

在光学影像内部，本文还需要选择分辨率范围。分辨率过低时，车辆、小型船舶等目标只剩几个像素，任何语义方法都缺乏可用的视觉证据；分辨率过高时，影像覆盖范围小，开放查询的业务价值下降。DOTA、DIOR 和 FAIR1M 的影像大多处于亚米到数米的范围[1-3]，既能保留主要目标的形态特征，又覆盖了足够大的地理范围，因此本文以这一分辨率范围作为研究对象。

1.3 共性挑战及其对决策的影响

光学遥感目标检测本身已有几项公认难点，开放词汇设定会把它们与语义问题叠加。俯视视角使许多类别失去在自然图像中最具判别力的侧面轮廓，船舶、车辆和集装箱在顶视下都接近长方形；目标尺度从几个像素的小型车辆跨越到上千像素的机场和港区；船舶、飞机和桥梁等目标呈任意方向，水平框会包含大量背景，因此 DOTA 等基准采用旋转框标注[1]，Oriented R-CNN 等方法也以旋转候选作为两阶段检测的基础[5]。在开放词汇设定下，这些几何难点会直接干扰语义判断：水平框中混入的码头纹理会让“船”的区域特征更像“港口”，切片截断会让大型目标只剩局部，语义相似度随之下降。

视觉—语言域偏移是开放词汇设定新增的挑战。图文预训练模型学到的“船”主要来自侧面或斜视的照片，模型依赖的是船首、上层建筑和水线等侧面特征；在俯视影像中，这些特征退化为一个细长的色块和甲板上的纹理。类别名在文本空间中的远近也不一定反映俯视外观的远近，例如“网球场”与“篮球场”在文本中相近，在俯视影像中也相近，而“储油罐”与“圆形水池”在文本中相距较远，在俯视影像中却极易混淆。

这种文本相似与外观相似之间的错位，会让文本编码器给出的类别向量无法区分外观相近的类别。

分数不可解释是开放词汇设定下更隐蔽的挑战。固定类别检测器的分类头在训练时见过所有类别，各类分数的尺度在训练中被大致对齐；开放词汇检测器的分数来自区域特征与文本向量的相似度，不同查询词的文本向量分布不同，同一相似度值在不同查询下代表的把握程度并不相同。若用户对所有查询使用同一个阈值，就会在某些查询下漏掉大量正确结果，在另一些查询下放进大量误报。

表 1-1 归纳了本文关注的四类共性挑战。它们不是彼此独立的技术问题，而是沿着“查询—候选—排序—决策”链条依次放大：文本原型偏移导致正确目标没有候选，切片和框型不当造成漏检或背景污染，未校准的分数又把背景纹理推成高置信结果，最终由人工复核承担全部代价。

表 1-1 开放词汇遥感检测的共性挑战及其影响

挑战	在遥感影像中的表现	对开放词汇检测的影响	本文对应设计
视觉—语言域偏移	俯视形态、季节与传感器差异，图文预训练以地面视角为主	新类别文本嵌入与区域特征距离不稳定，召回下降	三层词汇原型与负向描述（4.2 节）
极端尺度与密集分布	小目标仅占数十像素，同一切片内大量相邻实例	候选覆盖不足，重复框与漏检并存	多尺度重叠切片与跨切片融合（4.3、4.4 节）
任意方向与细长形态	船舶、桥梁、跑道方向任意，长宽比悬殊	水平框引入背景，污染区域语义	水平框与旋转框协同（4.3 节）
分数不可解释	原始相似度随查询词、类别频率和区域变化	高置信误报与低置信正确结果混杂，阈值难以设定	证据分解、事后校准与三态决策（4.5 节）

注：表中“表现”一栏依据 DOTA、DIOR 与 FAIR1M 原文对数据特性的描述[1-4]，“影响”一栏为本文基于方法机制的推断，将在第 5 章通过消融实验检验；表中不含实测数值。

1.4 研究问题链与本文工作边界

本文按“领域—子领域—挑战—方法—缺口—设计—验证”的顺序组织研究问题。领域层面要回答开放词汇检测为何值得在遥感中研究，答案来自业务查询的开放性与重新标注成本之间的矛盾；子领域层面要回答为何聚焦光学影像检测，答案已在 1.2 节给出；挑战层面要说明遥感特性如何放大开放词汇方法的弱点；方法层面要比较现有路线各自依赖的假设和失效条件；缺口层面要指出哪些问题在现有工作中尚未被同时处理；设计层面要给出可检验的方案与取舍依据；验证层面要给出能够推翻方案的实验。

图 1-1 用同一港区影像示意本文关注的任务变化。左侧是固定类别检测：模型只能在训练时定义的若干类别中作答；中间是开放查询：用户输入的词语可能指向训练集外的目标，系统需要为其生成候选；右侧是本文强调的决策阶段：密集小目标、任意方向目标与新类别候选同时出现时，系统需要说明哪些结果可以直接采用、哪些需要人工复核、哪些应当拒识。

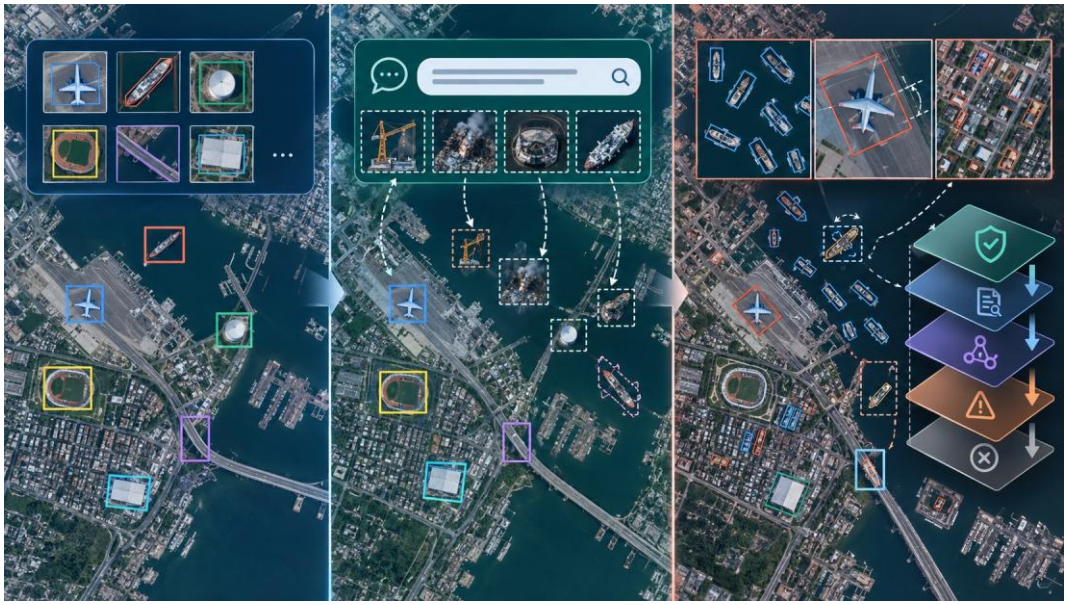


图 1-1 从固定类别检测到开放查询与分级决策的任务演变（示意图，不代表实测结果）

本文的贡献可以概括为一句话：在遥感开放词汇检测中，把语义适配、几何协同和可靠性校准放在同一个可消融的框架中设计，并为每项设计预先规定会推翻它的实验结果。具体而言，本文在方法上提出以三层原型与负向描述适配遥感语义、以水平框与旋转框协同改善区域纯度、以证据分解与事后校准支持三态决策的方案；在评测上提出同时覆盖新类泛化、几何分组、校准、查询一致性和跨域迁移的实验方案，并给出信息泄漏的控制规则；在应用上提出以证据卡连接模型输出与人工复核的设计，并用复核时间实验检验其作用。

本文的工作边界需要事先说明。本文提出一套方法设计与评测方案，并给出系统实现框架；截至本文撰写时，主实验和消融实验尚未运行，因此正文中所有性能描述均为假设或计划，对应表格以“待实测”标注。本文引用的已有方法数值均来自原论文，各自的数据划分和评测协议不同，不能直接横向比较，引用时只用于说明方法路线的特点。

1.5 本文结构

第 2 章按技术路线梳理遥感检测基准、通用开放词汇检测、遥感视觉—语言表示、遥感开放词汇检测以及置信度校准研究，并归纳尚未解决的问题。第 3 章给出任

务定义、设计原则和四项可证伪假设。第 4 章说明 OpenRSI-Calibrator 的三个核心模块及其计算成本。第 5 章给出逐项对应假设的实验方案，包括数据划分、对照方法、指标含义、统计方法、案例研究和停止规则。第 6 章说明系统实现、应用场景与部署约束。第 7 章总结本文的设计判断与研究局限。

第 2 章 相关研究与研究缺口

第 1 章把问题归结为视觉—语言域偏移、几何干扰与分数不可解释三类挑战。本章不逐篇罗列文献，而是按“每条路线依赖什么假设、在遥感影像中哪一条假设会失效”来组织。2.1 节说明遥感检测基准与旋转框检测奠定的问题形态；2.2 节比较通用开放词汇检测的四条路线；2.3 节讨论遥感视觉—语言表示；2.4 节分析已有的遥感开放词汇检测工作；2.5 节汇总置信度校准与开放词汇评测方面的负面证据；2.6 节据此提出本文要解决的问题。

2.1 遥感检测基准与旋转框检测

遥感检测基准的演进主要沿着两个方向推进：扩大实例规模和细化几何表示。DOTA 最早系统性地采用 8 个自由度的任意四边形标注，使旋转框成为航空影像检测的标准表示[1]；DIOR 虽然采用水平框，但通过 23463 幅影像覆盖了不同成像条件、季节和天气，突出尺度变化与类间相似带来的困难[2]；FAIR1M 在旋转框基础上引入细粒度子类，例如将飞机、船舶细分为具体型号，并附带经纬度和分辨率信息[3]；DOTA-v2.0 则把实例规模扩大约一个数量级，并配套给出 10 种算法、70 余种配置的速度与精度基线[4]。表 2-1 汇总了这四个基准的规模与标注形式。

表 2-1 主要光学遥感检测基准的规模与标注形式

基准	影像数/幅	类别数/个	实例数/个	标注框	对本文的作用
DOTA-v1.0	2806	15	188282	旋转框	旋转候选与小目标评测
DIOR	23463	20	192472	水平框	基础类/新类划分的主数据
FAIR1M	≥15000	37（子类）	≥1000000	旋转框	细粒度与层级查询评测
DOTA-v2.0	11268	18	1793658	旋转框	跨数据集迁移与规模压力测试

注：数据来源为各基准原论文摘要[1-4]；FAIR1M 原文仅给出“超过”的下限值，表中以“≥”标示；“对本文的作用”为本文实验设计中的用途，详见 5.2 节。

图 2-1 将同样的数据画在“类别数—实例数”平面上。实例数在对数坐标上跨越约一个数量级，类别数却始终处在 15 至 37 之间。这说明遥感检测基准的扩展主要发生在“同类目标更多”这一维度，而不是“可识别的目标种类更多”。即便未来继续增加标注，封闭类别表也很难覆盖业务中不断出现的新查询，这正是开放词汇方法需要回答的问题。

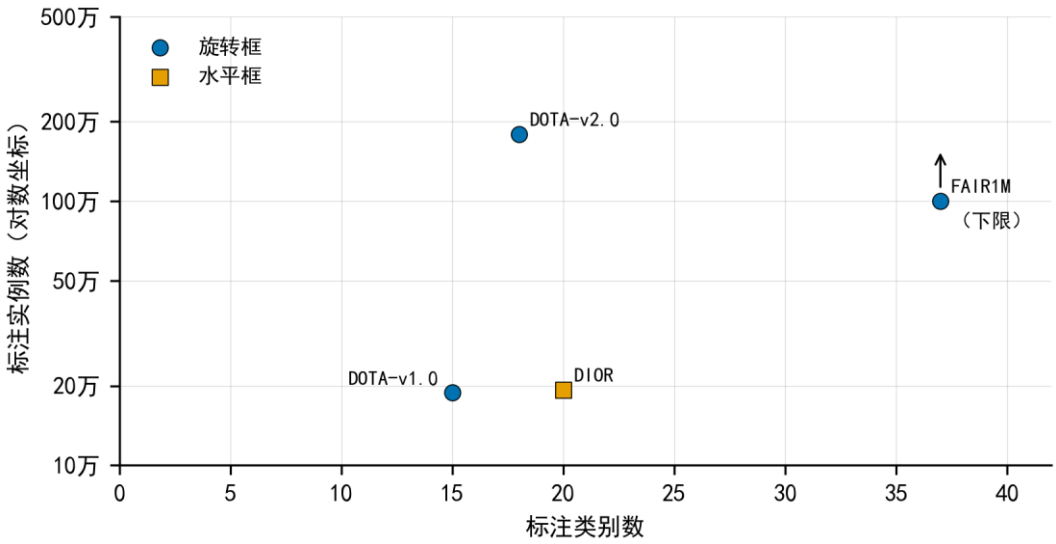


图 2-1 主要遥感检测基准的类别数与实例数（纵轴为对数坐标；FAIR1M 为原文给出的下限值）

旋转框检测方法为本文提供了几何基础。以 Oriented R-CNN 为代表的两阶段方法先生成有向候选，再在旋转感兴趣区域内提取特征并回归角度，在 DOTA 等基准上成为常用的强基线[5]。这类方法证明了旋转候选对细长、任意方向目标的必要性，但它们的分类头仍是固定类别的线性层，无法接受新的类别词。本文借用其几何表示与旋转交并比计算，把开放词汇能力放在分类与排序环节。

遥感检测基准的评测方式也对本文的实验设计有直接影响。DOTA 的影像尺寸远大于检测器输入，常见做法是先把大图切成重叠的子图训练和推理，再把子图结果映射回整图并合并重复框，最后在整图上计算指标；DOTA-v2.0 的作者为此提供了统一的代码库和评测服务[4]。这意味着在遥感检测中，“切片—合并”不是可有可无的工程细节，而是评测协议的一部分，切片参数不同的两个结果并不严格可比。本文在第 5 章把切片参数作为实验因素显式记录，并要求对照方法使用相同的切片与合并流程。

2.2 通用开放词汇检测的四条技术路线

自然图像上的开放词汇检测大致可以分为四条路线，它们的核心差异在于“视觉—语言对应关系从哪里来”。第一条路线是知识蒸馏。ViLD 用预训练图文模型的图像编码器为候选区域生成嵌入，再训练检测器的区域特征去拟合这些嵌入，同时用文本编码器生成类别向量[6]。该路线在 LVIS 上把稀有类作为新类留出，使用 ResNet-50 骨干取得 16.1 的稀有类掩码 AP[6]。RegionCLIP 进一步在区域与文本之间做对齐预训练，缓解了整图级图文模型在区域粒度上的错配[7]。这一路线的隐含假设是：教师模型对候选区域的判断是可靠的，而当候选区域本身来自俯视影像时，这一假设就需要重新检验。

第二条路线是弱监督扩展词汇。Detic 利用图像级标签训练检测器的分类头，把可检测类别扩展到两万量级[8]。它的假设是图像级标签可以较好地转移到最大的候选框上，这在以单个显著目标为主的自然图像中较为合理，但在一幅遥感影像包含数百个同类小目标时，图像级标签无法提供实例级定位信息。

第三条路线把检测重写为短语定位。GLIP 将类别名拼接成文本，用短语与区域的对齐来统一检测与定位任务[9]；Grounding DINO 在 DETR 式检测器中加入跨模态特征融合，并在大规模定位数据上预训练，成为开放集检测中常用的强基线[10]。这一路线对复杂描述的支持最好，但对文本的依赖也最强：描述换一种说法，候选和分数都可能变化，查询稳定性因此成为必须单独评测的指标。

第四条路线强调端到端迁移与实时部署。OWL-ViT 直接把图文预训练的视觉 Transformer 改造为检测器，结构简单、迁移方便[11]；YOLO-World 在 YOLO 框架中引入可重参数化的视觉—语言路径聚合网络和区域—文本对比损失，在 LVIS 上以 35.4 AP、52.0 FPS（V100）给出了速度与精度的平衡点[12]。这一路线适合交互式查询，但它们与前三条路线一样，预训练语料主要是地面视角图像。

表 2-2 比较了四条路线的核心假设、优势、局限和适用边界。比较的目的不是给出优劣排序，而是找出哪些假设会在遥感影像中失效，从而决定本文在何处做设计。

表 2-2 通用开放词汇检测四条路线的假设与适用边界

路线	代表工作	核心假设	主要优势	在遥感影像中的风险
知识蒸馏	ViLD、RegionCLIP	图文教师模型能正确判断候选区域	训练数据需求低，可复用检测器结构	教师模型缺少俯视语义，蒸馏会传递偏差
弱监督扩词	Detic	图像级标签可转移到主要候选框	词汇规模大，标注成本低	一图多实例时缺乏实例级定位依据
短语定位	GLIP、Grounding DINO	文本描述与区域可在统一空间中对齐	支持复杂描述与属性短语	对描述措辞敏感，查询稳定性差
端到端与实时	OWL-ViT、YOLO-World	图文预训练表示可直接迁移到检测	结构简单，推理速度快	小目标与旋转目标需额外适配

注：代表工作及其机制依据原论文[6-12]；“在遥感影像中的风险”为本文结合 1.3 节挑战作出的推断，其中语义偏移部分已有 2.4 节所述遥感工作的支持，其余将在第 5 章检验。

四条路线在评测协议上有一个共同点：新类的定义依赖于训练标注，而不依赖于预训练语料。ViLD 在 LVIS 上把稀有类作为新类留出[6]，YOLO-World 在 LVIS 上报告零样本结果[12]，但图文预训练语料本身可能已经包含这些“新类”的名称和图像。因此，开放词汇检测中的“新类”严格来说是“检测标注中未见的类”，而不是“模型从未接

触过的概念”。这一区别在遥感中更加重要：若某个新类在遥感图文语料中频繁出现，它对于模型就并不新；若某个新类在任何语料中都极少出现，模型对它的识别几乎只能依靠外观描述。本文在 5.2 节据此把新类分为“有先验”和“无先验”两组分别评测。

2.3 遥感视觉—语言表示的进展与边界

针对自然图像预训练的偏差，遥感社区构建了专门的视觉—语言表示。RemoteCLIP 汇集并扩充多个遥感数据源训练图文模型，报告在 12 个下游数据集上的平均零样本分类准确率比 CLIP 基线最多高出 6.39%[13]；RS5M 构建了约五百万规模的遥感图文对，并据此训练 GeoRSCLIP[14]；SkyScript 则着重提高语义多样性，覆盖更多细粒度地物类别[15]。这些工作共同表明，在遥感域内补充图文数据可以显著改善整图级语义对齐。

这些表示的边界同样清楚。它们主要在场景分类和图文检索上评测，评价对象是整幅影像或影像块，而检测需要的是实例级、甚至部件级的区域语义。整图级对齐好，并不保证一个只占 20×60 像素的船舶区域能与“渔船”而不是“码头”对齐。因此，本文把遥感视觉—语言模型视为原型构建的初始化来源和候选模型之一，而不是默认它已经解决了区域语义问题。

2.4 遥感开放词汇检测的代表性工作

遥感开放词汇检测的早期工作从零样本检测切入。DescReg 观察到航空目标的语义—视觉相关性较弱，即类别名称在文本空间中的相近程度与外观相似程度不一致，于是用描述外观的先验文本约束嵌入空间中的类间相似结构，在 DIOR 未见类上比此前最好的零样本方法高出 4.5 mAP，调和平均高出 8.1[16]。这一发现直接支持本文的原型设计：类别名本身不足以提供俯视影像需要的语义信息。

CastDet 采用师生自训练框架，以 RemoteCLIP 作为额外的教师模型改进新类候选与伪标签质量，并用动态标签队列维持伪标签质量，在 VisDroneZSD 新类上报告 46.5% mAP，比此前的开放词汇检测器高 21.0 个百分点[17]。LAE 工作把任务表述为“定位地球上的任意目标”，通过自动标注与统一来自多达 10 个遥感数据集的标注构建 LAE-1M，并提出带动态词表构建与视觉引导文本提示学习模块的 LAE-DINO，在 DIOR、DOTA-v2.0 和新建的 80 类 LAE-80C 上评测[18]。LAE 原文明确指出，以自然图像为主训练的开放词汇检测器由于域间差异难以泛化到遥感影像[18]，这是本文研究动机的直接文献依据。

在实时性方面，RT-OVAD 用图文对齐损失替代类别回归损失以解除类别约束，并以轻量的图文协同编码器和文本引导解码器提高精度，在 DIOR、DOTA-v2.0 和

LAE-80C 上分别报告 87.7 AP50、53.8 mAP 和 23.7 mAP，在 RTX 4090 上推理速度为 34 FPS，约为同文所测 LAE-DINO（10 FPS）的三倍[19]；OpenRSD 支持多模态提示和多任务检测头，同时输出水平框与旋转框，在七个公开数据集上评测，报告比 YOLO-World 平均精度高 8.7%，推理速度为 20.8 FPS[20]。表 2-3 从语义来源、旋转框输出、实时性和评测数据几个维度比较这些工作。

表 2-3 遥感开放词汇检测代表性工作的比较

方法	语义来源	旋转框输出	关注实时性	原文评测数据	本文视角下的未解决问题
DescReg	外观描述正则化	摘要未提及	否	DIOR、xView、DOTA	零样本设定，未处理分数可靠性
CastDet	RemoteCLIP 教师与伪标签	摘要未提及	否	VisDroneZSD 等	伪标签误差可能随新类扩散，摘要未报告拒识
LAE-DINO	大规模自动标注与动态词表	摘要未提及	否	DIOR、DOTA-v2.0、LAE-80C	自动标注噪声，未单独评测校准
RT-OVAD	图文对齐损失与图文协同编解码	摘要未提及	是	DIOR、DOTA-v2.0、LAE-80C	摘要未报告查询稳定性与校准
OpenRSD	多模态提示与多任务头	水平框与旋转框	是	七个公开数据集	未给出置信度校准与拒识评测

注：机制与评测数据依据各原论文摘要[16-20]；“摘要未提及”表示摘要中没有相应说明，不代表方法不具备该能力，需以正文与代码为准；最后一列为本文判断。各方法的数据划分不同，原文数值不能直接横向比较。

这些工作的评测协议差别很大。RT-OVAD 在 DIOR 上报告 IoU 阈值为 0.5 的 AP50，在 DOTA-v2.0 和 LAE-80C 上则报告 mAP[19]；CastDet 的代表性结果来自无人机视角的 VisDroneZSD[17]；OpenRSD 在七个数据集上取平均[20]。基础类与新类的划分、指标定义和数据集组合各不相同，原文数值之间几乎无法直接比较。这一现状本身就说明，遥感开放词汇检测还缺少一个被普遍接受的评测协议；本文第 5 章的做法是在同一套划分和评测脚本上复现主要对照方法，而不是引用原文数值作比较。

从表 2-3 可以看出，现有遥感工作已经分别处理了语义偏移（DescReg、CastDet、LAE-DINO）、实时性（RT-OVAD、OpenRSD）和旋转框输出（OpenRSD 在摘要中明确给出），但几乎都以平均精度作为唯一的主要结论指标，对于“分数能否被当作可靠程度使用”和“同一目标换一种问法结果是否一致”缺少系统评测。

2.5 置信度校准与开放词汇评测中的负面证据

在讨论负面证据之前，有必要说明校准的含义。一个校准良好的检测器，其输出分数为 0.8 的候选中应当约有 80% 是正确的；期望校准误差把分数区间划分为若干段，计算每段中平均分数与实际正确率之差，再按候选数加权平均。校准衡量的是分数能否被当作可靠程度使用，与检测器能否把正确目标排在前面是两回事：一个检测器可以排序完全正确而分数严重偏高，也可以分数校准良好而漏检很多。对于需要设定阈值、自动接受结果的应用，校准比排序更直接地决定误报风险。

置信度校准研究给出了第一组负面证据。Guo 等人指出，现代深度网络普遍存在过度自信，并提出以温度缩放作为简单有效的事后校准方法[21]。检测任务的情况更复杂：Küppers 等人发现检测器的校准误差与候选框的位置和尺寸有关，提出按位置和尺寸条件计算的检测期望校准误差（D-ECE）[22]。Kuzucu 等人则进一步指出，当时流行的“D-ECE 加温度缩放”评测框架存在缺陷，可能导致错误结论；在设计得当的评测下，Platt 缩放和保序回归等廉价的事后校准器优于训练时校准方法，以 D-DETR 为例，在 COCO 上的 D-ECE 比 Cal-DETR 低 7 以上[23]。这组证据说明，校准方法的选择和校准指标的定义都会影响结论，本文必须同时报告多种校准指标，并把事后校准作为强基线。

上述校准研究都在固定类别检测器上进行。本文推断，开放词汇检测的校准问题会更严重，原因有二。其一，固定类别检测器的校准器可以按类别分别拟合，而开放词汇检测器在推理时遇到的新类没有任何校准样本，只能依赖在基础类上拟合的校准器向新类外推。其二，开放词汇检测器的分数来自区域特征与文本向量的相似度，不同查询词的文本向量在嵌入空间中的分布不同，同一校准映射未必适用于所有查询。这两点目前缺少遥感领域的实证研究，本文在实验 E2 中把“基础类校准、新类测试”作为主要设置，专门检验校准能否外推。

开放词汇评测给出了第二组负面证据。OVDEval 构建了 9 个子任务，引入常识、属性、位置和关系理解等困难负样本，发现当时的主流开放词汇检测模型除简单物体类型外在这些任务上普遍失败；它还指出传统 AP 指标在细粒度标签上会给出误导性结果，因此提出 NMS-AP[24]。这意味着：在开放词汇设定下，仅报告标准 AP 可能高估模型对属性短语和细粒度描述的理解能力，本文的评测因此加入同义查询、属性短语和困难负样本三类设置。

2.6 尚未解决的关键问题

综合 2.1 至 2.5 节，本文认为遥感开放词汇检测还存在三个尚未被同时处理的问题。第一，语义适配与几何适配被分开研究。遥感视觉—语言表示和描述正则化改善了语义对齐[13-16]，旋转框检测改善了几何表示[5]，但在开放词汇设定下，水平框引入

的背景会反过来污染区域语义；两者之间的相互作用缺少受控实验，现有工作也很少报告“换用旋转候选后新类召回是否变化”。

第二，开放词汇检测的输出缺少可靠性语义。现有遥感方法几乎都只报告平均精度[17-20]，而校准研究表明检测分数需要专门的事后处理和条件化评测才能被解释为可靠程度[21-23]。对于需要人工复核的业务场景，无法判断“哪些结果可以直接采用”，开放词汇能力就只能停留在演示层面。

第三，查询的措辞稳定性没有被纳入评测。短语定位路线对描述措辞敏感[9-10]，OVDEval 也表明细粒度描述会让主流模型失效[24]，但遥感开放词汇工作尚未系统报告同义词、上下位词和属性短语下的结果一致性。用户在业务中不会只用数据集中的标准类名提问，这一缺口会直接影响系统的可用性。本文的方案和实验均围绕这三个问题展开：第 3 章把它们转化为可证伪假设，第 4 章给出对应的设计，第 5 章给出检验方法。

需要说明的是，以上三个问题是本文基于已检索文献作出的判断，检索范围以截至 2025 年上半年公开的预印本和会议论文为主，以论文摘要、方法描述和公开代码说明为依据。本文的检索在以下条件满足时停止：四条通用开放词汇路线、遥感视觉—语言表示和遥感开放词汇检测的代表性工作均已覆盖；每个缺口都至少有一篇直接相关的文献作为依据；已发现的相互冲突的结论，例如校准评测框架之争，已在正文中说明。未覆盖的方向包括遥感指代表达理解和遥感视觉问答，它们与开放词汇检测相关但任务定义不同；若后续发现已有工作系统处理了上述某个缺口，本文的定位需要相应修正。

第 3 章 研究设计与可证伪假设

第 2 章归纳的三个问题都可以用“如果……那么……否则……”的形式检验。本章先给出任务的形式化定义和符号，再说明方案在几个关键设计点上的取舍依据，最后把研究主张写成四项可证伪假设，并为每项假设预先规定会推翻它的实验结果。

3.1 任务定义与符号

设一幅光学遥感影像为 I，其尺寸通常远大于检测器的输入分辨率。用户给出一个查询 q，它可以是标准类名（如“储油罐”）、同义词（如“油罐”）、上下位词（如“船舶”与“集装箱船”）或带属性的短语（如“受损的码头”）。训练阶段可见的类别集合记为基础类集合 C_b，评测阶段额外引入且训练中从未作为监督信号出现的类别集合记为新类集合 C_n，二者互不相交。

检测器对查询 q 输出候选集合 $D=\{(b_i, s_i, p_i, a_i)\}$。其中 b_i 为候选框，可以是由中心、宽、高表示的水平框，也可以是附加角度 $\theta_i\in[-90°,90°)$ 的旋转框；s_i 为原始匹配分数；p_i 为经过校准后的可靠程度估计；a_i 为三态决策，取值为接受、复核或拒识。与常规开放词汇检测相比，本文要求输出中同时包含 p_i 和 a_i，因为业务使用者需要的不只是排序，而是“哪些结果可以直接用”的判断。

评测设定沿用开放词汇检测的常见划分。只在 C_n 上计算的指标衡量新类泛化能力；只在 C_b 上计算的指标衡量开放词汇改造是否损害原有能力；在 $C_b\cup C_n$ 上联合计算的广义设定最接近真实使用场景，因为用户并不知道哪些类别属于训练集。本文同时报告三种设定，避免只挑选对方案有利的设定。

广义设定还暴露一个常被忽略的问题：基础类与新类在同一影像中竞争候选。若模型对基础类过度自信，一个新类目标可能被错误地匹配到外观相近的基础类上，例如新类“散货船”被匹配为基础类“船舶”。在只评测新类的设定中，这类错误不会出现，因为评测时只查询新类；在广义设定中，它会同时降低新类召回和基础类精确率。本文因此把广义设定下“新类被基础类吸收”的比例作为一项诊断指标单独统计。

为了让排序和决策都能被解释，本文把每个候选的排序分数分解为四项证据的组合：

$$s_i = \alpha\cdot s_{sem}(i) + \beta\cdot s_{geo}(i) + \gamma\cdot s_{bg}(i) + \delta\cdot s_{stab}(i) \tag{3-1}$$

其中 s_{sem} 为区域特征与查询原型之间的语义匹配分数，s_{geo} 为候选框的几何质量估计，s_{bg} 为背景对照分数，衡量候选与同一影像中水面、屋顶、道路等背景原型的区分程度，s_{stab} 为查询稳定性分数，衡量同一候选在同义查询下的排名一致程度。权重 α、β、γ、δ 只在验证集上确定，确定后冻结，不允许根据测试集结果调整。

分解式 (3-1) 的作用不在于权重本身，而在于可解释性：当一个候选得到高分时，系统可以说明高分来自语义相似、框位置准确、背景区分良好还是查询稳定；当一个候选被拒识时，也可以指出是哪一项证据不足。第 4 章的三态决策和第 6 章的证据卡都建立在这一分解之上。

3.2 设计原则与取舍依据

方案设计遵循三条原则。第一，不把任何未经检验的环节默认为可靠，每个模块都必须有可单独关闭的开关，以便消融实验归因。第二，优先选用已被证明有效的强基线作为构件，例如以 Grounding DINO 或 YOLO-World 作为候选生成器、以事后校准作为可靠性基线，把研究精力集中在遥感特有的问题上。第三，任何提高某一指标的设计，都要同时报告它对其他指标和计算成本的影响。

在这些原则下，本文在语义适配方式、候选框表示、大图处理、可靠性估计和决策输出五个设计点上作出了取舍。表 3-1 列出了每个设计点的备选方案、本文的选择、理由以及需要付出的代价，其中前两项决定了方案能否找到新类目标，后三项决定了找到的结果能否被使用。

表 3-1 关键设计点的取舍

设计点	备选方案	本文选择	选择理由	代价与风险
语义适配方式	全量微调视觉—语言模型；提示学习；外部原型库	外部原型库，附带少量可学习投影	新类无需重训骨干，原型增删可审计	原型质量依赖描述写法，需要版本管理
候选框表示	只用水平框；只用旋转框；两者协同	两者协同，旋转证据不足时退回水平框	兼顾细长目标与角度预测不稳定的目标	融合逻辑更复杂，计算量增加
大图处理	整图缩放；固定切片；多尺度重叠切片	多尺度重叠切片	避免小目标在缩放中消失，减少边界截断	重复候选增多，需要跨切片融合
可靠性估计	直接用原始分数；训练时校准；事后校准	事后校准为主，比较多种校准器	已有证据显示事后校准是强基线且成本低	校准集需与测试集独立，跨区域可能失效
决策输出	单一阈值二分；排序列表；三态决策	接受、复核、拒识三态	与人工复核流程对应，可控制误报风险	需要额外设定两个阈值并说明依据

注：“选择理由”中关于事后校准的依据见文献[23]，关于域偏移的依据见文献[16,18]；其余理由为本文设计判断，将在第 5 章的消融实验中检验。

语义适配方式的选择最需要说明。LAE-DINO 采用视觉引导的文本提示学习，用可学习的向量增强文本特征[18]，这类方法的优点是能从数据中自动学到遥感域的表示，缺点是学到的向量不可读，新增类别时要么不经适配直接使用，要么需要新类数

据再训练。外部原型库的思路相反：把遥感域知识写成可读的文本描述，新增类别只需补写描述，不需要重新训练；代价是描述质量依赖人的经验，写得不好就会引入偏差。对于需要频繁响应新查询、并且要求结果可审计的业务场景，本文认为可读、可增删的原型库更合适。这一判断并不否定提示学习的价值，第 5 章会把 LAE-DINO 作为对照方法，并报告“原型库加在 LAE-DINO 之上”的组合结果，以检验两种思路是否互补。

可靠性估计的选择同样基于证据权衡。训练时校准通过修改损失函数让模型在训练中直接学到校准的分数，理论上可以与检测性能一起优化；事后校准只在训练后拟合一个从分数到可靠程度的映射，不改变排序。Kuzucu 等人的结果表明，在评测设计得当的情况下，事后校准不但成本低，而且效果优于训练时校准[23]。此外，事后校准可以施加在任何候选生成器之上，便于在对照方法之间公平比较。本文因此以事后校准为主，训练时校准仅在资源允许时作为补充比较。

需要说明的是，外部原型库并不意味着完全不训练。本文在冻结的视觉—语言骨干之上保留一个低维投影层，用基础类数据学习区域特征到原型空间的映射。这样做的风险是投影层可能过拟合基础类，导致新类性能下降；第 5 章的消融实验会专门比较“无投影”“基础类训练投影”和“基础类加描述正则训练投影”三种设置。

3.3 四项研究假设及其否证条件

本文的核心主张是：在遥感开放词汇检测中，语义适配、几何协同和可靠性校准需要放在同一框架下设计，并且各自的收益可以通过受控实验区分开。这一主张被拆解为四项假设，前三项分别对应 2.6 节的三个缺口，第四项检验方案对实际使用者的价值。假设的写法遵循一个原则：每项假设都要指出收益应当出现在哪里、不应当出现在哪里，因为只说“性能提高”的假设几乎无法被否证。

H1（域内原型）：以三层原型和负向描述构建的遥感域词汇原型，能够提高新类召回率，并且这一收益在跨区域测试集上依然存在。若收益只出现在与训练集同源的测试区域，而在跨区域测试中消失，则说明原型学到的是区域纹理而非可迁移语义，H1 被否证。

H2（几何协同）：水平框与旋转框协同的收益主要集中在小目标、细长目标和任意方向目标上，而不是通过增加候选数量换取召回。若旋转框带来的平均精度提升在按目标尺寸和长宽比分组后均匀分布，或者伴随每图候选数显著增加而精确率下降，则 H2 被否证。

H3（可靠性校准）：语义—区域一致性、背景对照与事后校准的组合，能够在新类召回下降不超过预设容差的前提下，降低期望校准误差和高置信误报率。若校准指标改善但风险—覆盖曲线没有改善，或者召回下降超过容差，则 H3 被否证。

H4（决策支持）：在三态决策和证据卡的辅助下，人工复核单个候选所需的时间缩短，且复核结论的一致性不下降。若证据卡增加了阅读负担而复核时间没有缩短，则 H4 被否证。

四项假设各自对应一种可能的替代解释。对 H1 而言，替代解释是“收益来自区域纹理记忆”，因此必须用跨区域测试排除；对 H2 而言，替代解释是“收益来自候选数量增加”，因此必须同时报告每图候选数和精确率；对 H3 而言，替代解释是“校准只是把所有分数压低”，因此必须用风险—覆盖曲线而不只是校准误差来判断；对 H4 而言，替代解释是“复核人员对第二种条件更熟悉”，因此复核条件的顺序必须平衡。表 3-2 把每项假设与对应的实验、主要指标和否证条件对应起来。表中的数值阈值是预先设定的判定线，用于避免在看到结果后再选择有利的解释；阈值本身并非实测结果。

表 3-2 研究假设、检验实验与否证条件

假设	检验实验	主要指标	支持假设的结果	否证假设的结果
H1 域内原型	主实验 E1、消融 A1—A2、跨区域 E4	新类召回、新类 mAP、跨区域差值	新类召回提升，且跨区域测试中提升的 95% 置信区间不含 0	跨区域提升的置信区间包含 0 或为负
H2 几何协同	消融 A3、按尺寸与长宽比分组分析 E3	旋转框 mAP、小目标平均召回、每图候选数	收益集中于小目标与长宽比大于 4 的目标	收益在各组均匀分布，或候选数增加一倍以上而精确率下降
H3 可靠性校准	消融 A4、校准器比较 E2	D-ECE、Brier 分数、高置信误报率、新类召回	校准指标改善，新类召回下降不超过 2 个百分点	风险—覆盖曲线无改善，或召回下降超过 2 个百分点
H4 决策支持	人工复核实验 E5	单候选复核时间、复核者间一致性	复核时间缩短且一致性不下降	复核时间不变或延长，或一致性下降

注：表中阈值（95% 置信区间、长宽比 4、候选数一倍、召回容差 2 个百分点）为本文预先设定的判定线，依据见 5.8 节；所有实验均为待实测项。

四项假设之间存在依赖关系：H3 的校准建立在 H1 和 H2 提供的候选之上，H4 的复核实验又依赖 H3 给出的三态决策。因此实验按 H1、H2、H3、H4 的顺序推进；若前一项被否证，后续实验仍然执行，但结论的解释范围相应收窄，例如 H1 被否证时，H3 的结论只适用于基础类和同域测试。

3.4 研究边界与不作承诺的部分

本文的结论适用于空间分辨率在亚米到数米之间的光学遥感影像，以及具有明确空间范围的离散目标。连续地物（如植被覆盖、水体范围）属于分割问题，不在本文

讨论范围内。查询语言以中文和英文类名、短语为主，不处理需要多步推理的复杂指代，例如“距离加油站最近的第二个停车场”。

本文不承诺开放词汇检测能识别任意类别。对于在任何遥感图文语料中都极少出现、且外观与已知类别差异很大的目标，原型构建缺乏依据，本文预期其召回会显著偏低，并将在失败分析中单独统计这类“无先验新类”。本文也不承诺系统输出可以替代专业解译人员的最终判断：三态决策中的“接受”只表示在当前校准下误报风险低于预设水平，涉及灾害定级、执法和资源调度的结论仍须由人工确认。

第 4 章 OpenRSI-Calibrator 方法

4.1 总体框架

第 3 章在语义适配、候选框表示、大图处理、可靠性估计和决策输出五个设计点上作出了取舍，本章把这些取舍落实为具体模块。OpenRSI-Calibrator 由五个层次组成，图 4-1 自上而下给出了它们的关系。输入层接收大幅遥感影像和用户查询，把影像切分为多尺度重叠切片，并把查询规范化为对象词、属性词和场景词。表示层用视觉—语言骨干分别编码切片区域和查询文本，并把查询映射到遥感域原型空间。候选层在每个切片内生成水平框与旋转框候选，再映射回整图坐标做跨切片融合。决策层按式 (3-1) 计算四项证据，经校准后给出接受、复核或拒识三种状态。记录层把每个结果的查询、切片来源、各项分数、校准参数和人工复核结论保存为证据卡，供回放和审计使用。

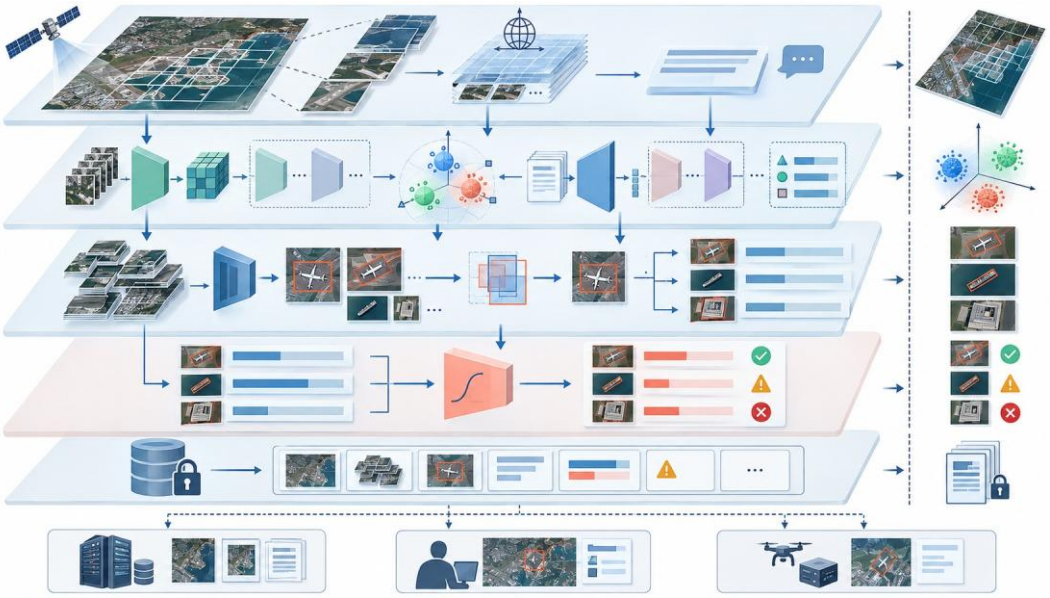


图 4-1 OpenRSI-Calibrator 的五层框架：输入切片与查询、视觉—语言表示与原型空间、水平框与旋转框候选及融合、校准后的三态决策、证据记录与多端部署（示意图）

五个层次之间只通过明确的数据接口交互。候选层只依赖表示层输出的区域特征和原型向量，不关心骨干网络的具体实现，因此 Grounding DINO、YOLO-World 或遥感专用模型都可以作为候选生成器接入；决策层只依赖候选层输出的原始分数和几何信息，因此校准方法可以独立替换和比较。这种分层是消融实验能够归因的前提：每关闭一个模块，其他模块的输入输出格式不变。

查询规范化是输入层中容易被忽视的一步。用户输入“港口里受损的仓库”时，系统把它拆为对象词“仓库”、属性词“受损”和场景词“港口”，并分别保存。对象词决定候选召回，属性词用于重排，场景词提供背景先验。若拆分后没有任何对象词，例如

用户只输入“受损的”，系统不会猜测对象，而是提示查询缺少目标类别；若对象词不在原型库中，系统使用该词的文本编码作为临时对象原型，并在输出中标明“无遥感原型”，使用者据此知道该查询的结果可靠性较低。

4.2 遥感域词汇原型适配

4.2.1 三层原型的构成

直接用类别名作为文本输入有两个问题。其一，类别名在文本空间中的远近与俯视外观的远近不一致，DescReg 将其概括为航空目标“语义—视觉相关性弱”[16]；其二，许多查询本身包含属性或场景信息，把整句压缩成一个向量会丢失可解释性。本文因此把每个查询拆分为三层原型：对象原型描述目标在俯视影像中的可见形态与功能类别，例如“船舶”对应“细长、一端尖、常靠泊于码头或位于水面”；属性原型描述颜色、状态、材质或损伤，例如“受损”对应“屋顶不完整、边缘破碎、周围有散落物”；场景原型描述目标通常出现的上下文，例如港区、机场、道路和农田。每层原型由若干条文本描述编码后取均值得到。设第 k 层的描述集合为 T_k，其中包含 n_k 条描述，文本编码器为 $g(\cdot)$，则该层原型为

$$t_k = \mathrm{norm}\left((1/n_k) \cdot \Sigma_{\tau \in T_k} g(\tau) \right) \tag{4-1}$$

其中 $norm(\cdot)$ 表示 L2 归一化。对象层原型必须存在，属性层和场景层原型只在查询包含相应信息时生成。取均值而不是逐条匹配的考虑是：单条描述的写法偶然性较大，多条描述的均值更稳定；代价是若某一条描述明显错误，它的影响会被平均掉而不易被发现，因此原型库的版本记录中保留每条描述单独与验证集匹配的结果，便于定位有问题的描述。

4.2.2 负向描述与背景原型

仅有正向描述时，模型容易把与目标颜色或纹理相近的背景当作目标，例如把浅色屋顶当作储油罐、把码头边缘当作船舶。本文为每个对象原型补充负向描述和背景原型。负向描述说明“哪些相似物体不是该目标”，例如“储油罐”的负向描述包括“圆形水池”和“圆形建筑屋顶”；背景原型来自同一影像中自动采样的水面、屋顶、道路和阴影区域，用于计算式 (3-1) 中的背景对照分数 s_{bg}。图 4-2 示意了对象、属性、场景三类原型在嵌入空间中形成的簇，以及灰色的负向与背景原型如何为区域匹配提供对照。

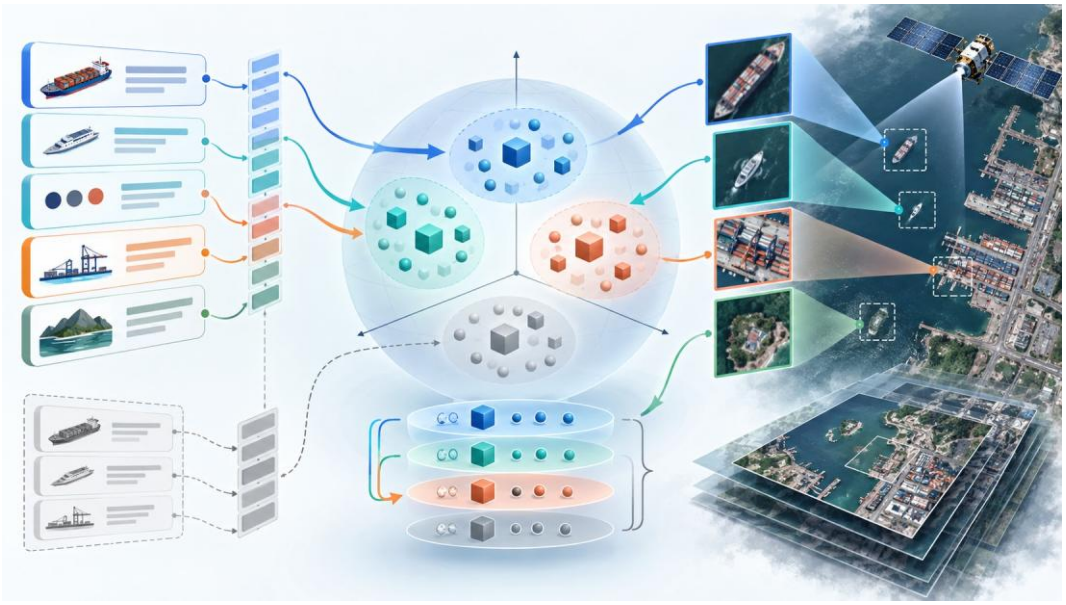


图 4-2 遥感域三层词汇原型示意：左侧文本描述经编码进入原型空间，彩色簇对应对象、属性与场景原型，灰色簇对应负向描述与背景原型，右侧为与之匹配的俯视影像区域（示意图）

区域 r 与查询之间的语义匹配分数定义为对象层相似度与经门控的属性层、场景层相似度之和，再减去与负向原型的最大相似度：

$$s_{sem}(r) = \cos(f_r, t_{obj}) + \Sigma_{k\in\{attr,scene\}}\, g_k \cdot \cos(f_r, t_k) - \lambda \cdot \max_{u\in N} \cos(f_r, u) \qquad (4\text{-}2)$$

其中 f_r 为区域特征经投影后的向量，$g_{k\in}[0,1]$ 为门控系数，由区域特征与该层原型的相似度经 Sigmoid 函数得到，用于抑制没有视觉证据支持的属性或场景信息；N 为负向原型与背景原型的集合；λ 为惩罚系数，在验证集上确定。式 (4-2) 中负向项取最大值而不是平均值，是因为只要候选与任何一个负向原型高度相似，就足以构成拒识理由；取平均会让大量不相关的负向原型稀释这一信号。

背景对照分数 s_{bg} 与式 (4-2) 中的负向项相关但不相同。负向项来自人工撰写的、跨影像通用的负向描述；s_{bg} 来自当前影像中自动采样的背景区域，反映的是“这个候选与本幅影像的背景有多大区别”。一个候选可能与“圆形水池”的通用描述不相似，却与本幅影像中大量出现的某种屋顶非常相似，这时 s_{bg} 能捕捉到通用负向描述遗漏的情况。s_{bg} 定义为 1 减去候选与当前影像背景样本特征的最大余弦相似度。

4.2.3 投影层的训练目标

如 3.2 节所述，本文在冻结的视觉—语言骨干之上训练一个低维投影层 P，把区域特征映射到原型空间。训练只使用基础类的标注，目标是让区域特征靠近其所属类别的对象原型，远离其他类别的原型以及负向原型。对一个标注为类别 c 的区域，损失函数为

$$L = -\log\left(\exp(\cos(P f_r, t_c)/\kappa) \,/\, \Sigma_{c'\in CbuN} \exp(\cos(P f_r, t_{c'})/\kappa) \right) + \mu \cdot L_{desc} \qquad (4\text{-}3)$$

其中 κ 为温度系数，分母同时包含所有基础类原型和负向原型；L_{desc} 为描述正则项，借鉴 DescReg 的思路[16]，要求投影后的类别间相似度结构与外观描述之间的相似度结构保持一致，以减少投影层对基础类的过拟合；μ 为正则系数。正则项的作用是：新类在训练中从未出现，若投影层只学会区分基础类，新类原型落到投影空间后的位置就无法预测；保持描述相似度结构，相当于要求投影层保留“哪些类别外观相近”这一可迁移的信息。

4.2.4 原型来源与版本管理

原型描述的来源决定了它的可信程度。本文按优先级使用三类来源：第一类是遥感数据集的官方类别定义和标注说明，第二类是遥感图文数据集（如 RS5M、SkyScript）中与该类别对应的描述文本[14-15]，第三类是由领域人员撰写并经交叉检查的外观描述。任何一类来源都不能直接使用测试集影像或标注生成描述，以免造成信息泄漏。

原型库按版本保存，每次增删描述都记录变更内容、来源和在验证集上的指标变化。这一要求看似属于工程管理，实际上关系到实验结论的有效性：若在观察测试集结果后修改描述，相当于用测试集调参，新类指标会被系统性高估。第 5 章的泄漏控制规则会把原型库版本的冻结时间写入实验记录。

4.3 多尺度切片与旋转候选协同

4.3.1 多尺度重叠切片

遥感影像的尺寸通常远大于检测器的输入分辨率，整图缩放会让小目标只剩几个像素。本文采用多尺度重叠切片：在原始分辨率上以较小切片保留小目标细节，在下采样后的影像上以较大切片保留大型目标和上下文。相邻切片之间保留一定比例的重叠区域，使跨越切片边界的目标至少在一个切片中完整出现。

重叠率的下限可以从目标尺寸推出。设切片边长为 W，重叠宽度为 o，某类目标在该尺度下的最大边长为 $l_{\max}$。若 $o \geq l_{\max}$，则任何长度不超过 $l_{\max}$ 的目标都至少在一个切片中完整出现。因此，对于原始分辨率尺度，重叠宽度应不小于需要完整检出的最大目标边长；超过这一长度的目标交给下采样尺度处理。这一推理给出了切片参数的选择依据，但重叠越大，切片数越多，计算成本越高，实际取值仍需在验证集上权衡。切片尺寸、重叠率和每个切片的最大候选数都作为实验因素记录，而不是固定的超参数。

图 4-3 左侧示意了港区影像上的重叠切片网格，红色与蓝色虚线框分别表示两个相邻切片，同一艘船舶同时出现在两个切片中，其中一个切片中的船体被截断。

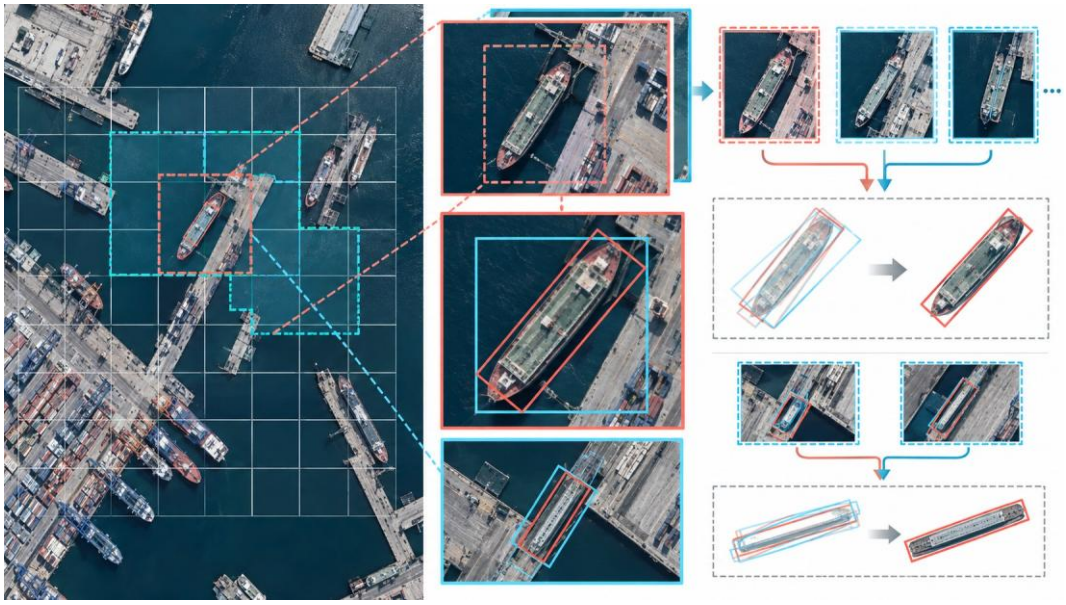


图 4-3 多尺度重叠切片与旋转候选协同：左为切片网格及相邻切片的重叠区域，中为同一船舶在不同切片中的水平框（蓝）与旋转框（红），右为多个切片的重复候选在整图坐标下融合为单一旋转框（示意图）

4.3.2 水平框与旋转框的协同

图 4-3 中间一列显示了同一船舶的水平框与旋转框。对于倾斜的细长目标，水平框中有相当比例的面积是水面和码头，区域特征因此混入背景语义。以长宽比为 ρ、倾斜 45° 的矩形目标为例，其外接水平框的面积是目标本身面积的 $(1+\rho)^2/(2\rho)$ 倍；当 $\rho=5$ 时约为 3.6 倍，即水平框中超过七成的面积是背景。旋转框能更紧密地贴合目标，但角度预测对噪声敏感，在目标轮廓模糊或近似正方形时可能不稳定。

本文的协同策略是：候选生成器同时输出水平框与旋转框，对每个旋转候选估计角度可信度 c_θ。当 c_θ 高于阈值时，以旋转框裁剪区域计算语义分数；否则退回水平框，并在输出中标注“旋转不确定”。角度可信度由两部分组成：一是同一目标在相邻切片和不同尺度下预测角度的一致性，二是目标长宽比，长宽比接近 1 时角度本身缺乏意义。

$$c_\theta = \exp(-\sigma_\theta / \sigma_0) \cdot \min(1, (\rho - 1)/(\rho_0 - 1)) \tag{4-4}$$

其中 σ_θ 为同一目标在多个切片和尺度下预测角度的标准差，ρ 为长宽比，σ_0 和 ρ_0 为在验证集上确定的尺度参数。式 (4-4) 的设计意图是：角度预测越一致、目标越细长，旋转框就越值得信任。当一个目标只出现在一个切片中时，σ_θ 无法计算，此时只使用长宽比一项，并把该候选的几何质量相应调低。

几何质量分数 s_{geo} 综合了角度可信度与截断程度。设候选框被切片边界截断的面积比例为 η，则

$$s_{geo} = (1 - \eta) \cdot (\omega \cdot c_\theta + (1 - \omega) \cdot q_{box}) \tag{4-5}$$

其中 q_{box} 为候选生成器自身输出的定位质量估计，例如交并比预测分支的输出；若生成器不提供该项，则取 1；ω 为权重。截断项作为乘性因子，是因为一个被截掉一半的候选，无论角度多准确，都不应被当作高质量候选。

4.4 跨切片融合与冲突记录

切片带来的直接代价是重复候选。图 4-3 右侧示意了多个切片对同一船舶给出的重复旋转候选如何融合为单一结果。本文的融合分三步进行。第一步按空间网格和查询分桶，只在同一网格及相邻网格内比较候选，避免全局两两比较带来的平方级计算量。第二步用旋转交并比、中心距离和查询一致性判断两个候选是否属于同一目标；旋转交并比低但中心距离很近的情况，往往对应同一目标在两个切片中分别被截断，此时以中心距离为主要判据。第三步在属于同一目标的候选中，优先保留来自目标未被截断的切片、几何质量分数更高的候选，而不是简单地取最高语义分数。

融合过程中会出现冲突：两个候选几何上高度重叠，但最佳匹配的查询不同，例如一个更像“集装箱船”，另一个更像“散货船”。这种情况往往对应细粒度类别混淆，直接取最高分会掩盖不确定性。本文保留冲突记录，把这类候选标记为“语义冲突”并送入复核状态，同时在评测中单独统计冲突率。融合中记录的冲突类型包括语义冲突、几何冲突（同一目标的水平框与旋转框给出明显不同的位置）和来源冲突（不同尺度切片给出不一致的结论）三类。

这一设计把“没有检测到”与“检测到了但类别不确定”区分开来。在平均精度的计算中，二者都表现为分数下降，但它们对应的改进方向完全不同：前者需要改善候选覆盖，后者需要改善原型区分度或引入人工判断。

4.5 可靠性校准与三态决策

4.5.1 查询稳定性分数

式 (3-1) 中的查询稳定性分数 s_{stab} 需要单独说明。对每个查询 q，系统从原型库中取出它的同义词集合 $S(q)$，例如“储油罐”对应“油罐”和“储罐”。对每个同义查询分别计算候选排序，候选 i 的稳定性分数定义为它在各同义查询下排名的一致程度：

$$s_{stab}(i) = (1/|S(q)|) \cdot \Sigma_{q' \in S(q)} \, 1[\, rank_{q'}(i) \le k \,] \tag{4-6}$$

其中 $1[\cdot]$ 为指示函数，k 为预先设定的排名阈值。直观地说，若一个候选只在某一种问法下排在前面，换一种说法就掉出前 k 名，它很可能是由措辞偶然性带来的，而不是稳定的视觉证据。计算 s_{stab} 需要对每个同义查询重复匹配，但视觉特征可以复用，额外成本只在文本编码和相似度计算上。

4.5.2 校准方法

原始分数 s_i 是排序信号，不能直接解释为“该候选正确的概率”。校准模块把式 (3-1) 的组合分数映射为可靠程度估计 p_i。依据 Kuzucu 等人的结论，设计得当的事后校准器是强基线[23]，本文因此比较三种事后校准器。温度缩放[21]只有一个参数，把分数除以温度后经 Sigmoid 映射；Platt 缩放增加一个偏置项：

$$p_i = 1 / (1 + \exp(-(a \cdot s_i + b))) \tag{4-7}$$

其中 a、b 在校准集上以最大似然拟合；保序回归则不假设映射的函数形式，只要求映射单调不减，灵活性最高，但在校准样本少时容易过拟合。三种校准器只在独立的校准集上拟合，校准集与测试集在影像层面不重叠。

检测校准的特殊性在于，校准误差会随候选框的位置、尺寸而变化[22]。遥感影像中这一问题更突出：小目标和大目标的分数分布可能完全不同，同一阈值在不同目标尺度下对应的误报率也不同。本文因此在全局校准之外增加按目标尺寸分组的条件校准，并在评测中同时报告全局和分组的校准误差。分组校准需要每组都有足够的校准样本，若某组样本不足，则退回全局校准，并在结果中注明。

4.5.3 三态决策规则

校准后的可靠程度 p_i 与两个阈值 $\tau_h > \tau_l$ 共同决定候选的状态。表 4-1 给出了三种状态的判定条件和含义。

表 4-1 三态决策的判定条件

状态	判定条件	含义	后续动作
接受	$p_i \geq \tau_h$，且无冲突记录，且查询稳定性分数不低于下限	在当前校准下误报风险低于预设水平	直接进入结果列表，可抽检
复核	$\tau_l \leq p_i < \tau_h$，或存在冲突记录，或旋转不确定	证据不足以自动判定，但不应丢弃	进入人工复核队列并附证据卡
拒识	$p_i < \tau_l$，或背景对照分数显示与背景原型更相似	大概率为误报	不进入结果列表，保留日志供审计

注：依据为本文方法设计（4.5 节）；阈值 τ_h、τ_l 按式 (4-8) 在校准集上确定，确定后冻结；表中条件为方法设计，不代表实测效果。

阈值的确定方式比阈值本身更重要。设使用方给定“接受”状态可容忍的误报率上限为 ε_a，“拒识”状态中可容忍的漏检比例上限为 ε_r。在校准集上，τ_h 取满足误报率约束的最小阈值，τ_l 取满足漏检约束的最大阈值：

$$\tau_h = \min\{\, \tau : FP(p \geq \tau)/N(p \geq \tau) \leq \varepsilon_a \,\},\ \tau_l = \max\{\, \tau : TP(p < \tau)/N(p < \tau) \leq \varepsilon_r \,\} \tag{4-8}$$

其中 $FP(\cdot)$、$TP(\cdot)$ 和 $N(\cdot)$ 分别为满足条件的误报数、正确数和候选总数。两个风险水平由应用方根据人工复核成本事先给定，而不是根据测试结果倒推。若求得的 $\tau_l \geq \tau_h$，说明在当前校准质量下无法同时满足两个约束，此时系统不启用自动接受，所有非拒识候选都进入复核，并在报告中说明原因。

4.5.4 拒识的解释

拒识不是简单删除候选。每个被拒识的候选都附带拒识原因，即四项证据中哪一项最弱，以及与之最接近的替代查询词。例如，一个“储油罐”查询下被拒识的候选，可能附带“背景对照分数低，更接近圆形建筑屋顶原型”的说明。这样做有两个目的：一是让使用者理解系统为何不给出结果，二是为原型库的迭代提供线索，当某类拒识原因反复出现时，说明对应的负向描述需要补充。

4.6 计算复杂度与部署成本

设一幅影像被切分为 T 个切片，每个切片产生最多 K 个候选，查询数量为 Q。视觉编码的计算量与 T 成正比，文本与原型编码与 Q 成正比且可以缓存。朴素的跨切片融合需要对全部 TK 个候选两两比较，复杂度为 $O((TK)^2)$；按空间网格分桶后，每个候选只与相邻网格内的候选比较，复杂度降为 $O(TK \cdot m)$，其中 m 为相邻网格内候选数的平均值，取决于目标密度。表 4-2 列出了各模块的主要计算开销和可调节因素。

表 4-2 各模块的计算开销与可调节因素

模块	主要开销	复杂度	可调节因素	需要报告的成本指标
切片与视觉编码	骨干网络前向计算	$O(T)$	切片尺寸、重叠率、尺度数	每图切片数、显存峰值
原型编码	文本编码器前向计算	$O(Q \cdot n_d)$，可缓存	每层描述条数 n_d	原型库规模、缓存命中率
候选生成与匹配	检测头与相似度计算	$O(T \cdot K \cdot Q)$	每切片候选上限	每图候选数
查询稳定性	同义查询的相似度计算	$O(T \cdot K \cdot Q \cdot s)$	同义词数 s	额外耗时占比
跨切片融合	旋转交并比计算	$O(T \cdot K \cdot m)$	网格大小	融合耗时、冲突率
校准与决策	标量映射	$O(T \cdot K)$	无	可忽略

注：复杂度依据第 4 章各模块结构推导，为量级估计；具体耗时随硬件与实现而变，将在 5.5 节以中位数与第 99 百分位延迟实测报告。

部署成本主要取决于切片数量：单幅 10000×10000 像素影像在切片尺寸为 1024 像素、重叠率为 20% 时，仅原始尺度就需约 144 个切片。因此交互式场景应先在低分辨率尺度上给出候选，再按需细化，具体取舍见 6.4 节。

第 5 章 实验方案

本章给出检验第 3 章四项假设的完整实验方案。所有实验均尚未运行，表中的结果栏统一标注“待实测”。实验设计遵循一个基本要求：每项实验在运行前就写明它回答什么问题、用什么数据和对照、看哪个指标，以及什么结果会推翻原假设。

5.1 实验总览

表 5-1 列出了五项主实验与四组消融的对应关系。主实验 E1 到 E5 分别对应新类泛化、校准、几何分组、跨区域迁移和人工复核；消融 A1 到 A4 按模块逐个加入，用于把 E1 的整体收益归因到具体模块。

表 5-1 实验与研究问题的对应关系

编号	回答的问题	对应假设	数据	主要指标	推翻假设的结果
E1	完整方案在新类、基础类和广义设定上是否优于对照方法	H1、H2、H3	DIOR 与 DOTA-v1.0 划分	新类 mAP、新类召回、广义 mAP	新类指标不优于最强对照的置信区间下界
E2	哪种校准器在遥感开放词汇检测中最可靠	H3	DIOR 划分的校准集与测试集	D-ECE、Brier 分数、高置信误报率	所有校准器都未改善风险—覆盖曲线
E3	旋转候选的收益集中在哪类目标	H2	DOTA-v1.0 与 FAIR1M 划分	分组旋转框 mAP、小目标平均召回	收益在尺寸与长宽比分组中均匀分布
E4	收益能否迁移到未见区域与未见数据集	H1	跨区域与跨数据集划分	同域与跨域指标之差	跨域提升的置信区间包含 0
E5	证据卡能否缩短人工复核时间	H4	E1 测试集中抽样的候选	单候选复核时间、一致性系数	复核时间不缩短或一致性下降
A1—A4	每个模块各贡献多少	H1—H3	与 E1 相同	与 E1 相同	见 5.6 节

注：表中实验均为计划项，尚未运行；“推翻假设的结果”依据第 3 章表 3-2 预先设定。

5.2 数据集、类别划分与泄漏控制

5.2.1 基础类与新类划分

主实验以 DIOR 为主数据，以 DOTA-v1.0 为旋转框评测数据，以 FAIR1M 为细粒度评测数据。DIOR 的 20 个类别包括飞机、机场、棒球场、篮球场、桥梁、烟囱、水坝、高速公路服务区、高速公路收费站、高尔夫球场、田径场、港口、立交桥、船

舶、体育场、储油罐、网球场、火车站、车辆和风车[2]。若已有遥感开放词汇工作公开了 DIOR 的基础类与新类划分，本文优先沿用，以便与原文结果对照；同时按下述规则构造一个补充划分，用于检验结论对划分方式的敏感性。

补充划分的构造规则是：新类在三个维度上分层抽取，即目标尺寸（小、中、大）、外观形态（细长、紧凑、不规则）和与基础类的语义距离（存在上位类、仅存在相似外观类、无相近类）。这样选出的新类覆盖了不同难度，避免只挑选与基础类相近、容易泛化的类别。表 5-2 给出了各数据集的使用方式。

表 5-2 数据集的使用方式与划分规则

数据集	用途	类别划分	框类型	关键控制项
DIOR	主实验与校准实验	优先沿用已公开划分；补充分层划分	水平框	训练、校准、测试在影像层面互不重叠
DOTA-v1.0	旋转框与小目标评测	15 类中按同一规则划分	旋转框	大图按 4.3 节规则切片，评测在整图坐标下进行
FAIR1M	细粒度与层级查询评测	以大类为基础类、子类为新类	旋转框	只用于测试，不参与训练和调参
DOTA-v2.0	跨数据集迁移测试	与 DOTA-v1.0 不重叠的新增类别	旋转框	去除与训练集重复的影像

注：数据集规模与类别信息的来源为原论文[1-4]（见表 2-1）；划分规则为本文设计，具体类别清单在实验开始前随实验记录一并公开，划分确定后不再修改。

5.2.2 信息泄漏的来源与控制

开放词汇检测的评测结论很容易被三类信息泄漏削弱，本文分别规定了控制方法。第一类是预训练语料泄漏。视觉—语言骨干的预训练数据可能已经包含“新类”的名称和图像，所谓新类对模型并不陌生。对此本文无法完全消除，但可以度量：统计每个新类名称及同义词在 RS5M、SkyScript 等可获取的遥感图文语料中的出现频次[14-15]，把新类分为“有先验”和“无先验”两组分别报告。若方案的收益只出现在“有先验”组，结论就需要相应收窄。

第二类是跨数据集影像重叠。DIOR、DOTA 等数据集的影像来源有交叉的可能，同一地点的影像可能分别出现在训练集和测试集中。本文在实验前用感知哈希对所有参与实验的影像去重，并在跨区域测试中以地理范围而非影像编号划分，去重日志随实验记录保存。

第三类是调参泄漏。原型描述、融合阈值、校准参数和三态阈值都只能在验证集或校准集上确定。本文规定在第一次查看测试集结果之前，冻结原型库版本、所有超参数和随机种子；此后对任何设置的修改，都必须作为新的实验版本单独报告，不得覆盖原结果。

在数据切分比例上，本文把每个数据集的标注影像按地理范围或影像编号分为训练集、验证集、校准集和测试集四部分。验证集用于选择超参数和原型描述，校准集只用于拟合校准器和确定三态阈值，二者分开是为了避免校准器在已被用来调参的数据上拟合，从而低估真实的校准误差。若数据集官方提供了训练集与测试集划分，本文只在官方训练集内部再划出验证集和校准集，官方测试集保持不变，以便与其他工作对照。新类的全部标注只出现在验证集、校准集和测试集中；验证集和校准集中的新类标注用于调参和校准，测试集中的新类标注只用于最终评测。

这里有一个需要明确的取舍：在验证集和校准集中使用新类标注，意味着方案在调参时“见过”新类的少量样本，严格来说不是纯粹的零样本设定。本文采用这一做法，是因为三态阈值必须在包含新类的数据上确定，否则阈值对新类没有意义。为了区分这一影响，本文同时报告一个对照设置：验证集和校准集只含基础类，阈值完全由基础类确定后直接用于新类测试。两种设置的差距，反映了“少量新类样本用于校准”带来的增益。

5.3 对照方法与公平比较规则

对照方法覆盖第 2 章的主要路线，按“闭集上界、通用开放词汇、遥感开放词汇、校准基线”分为四组。选择对照方法的标准有三条：有公开代码或权重，能够在相同划分上复现；代表一条不同的技术路线，而不是同一路线的多个变体；在原文中报告过遥感或开放词汇基准上的结果。表 5-3 列出了各组的方法、选择理由以及使用方式。

表 5-3 对照方法及其选择理由

组别	方法	选择理由	使用方式
闭集上界	Oriented R-CNN	旋转框强基线，用全部类别监督训练，提供性能上界参照	在全部类别上训练，仅作参照
通用开放词汇	Grounding DINO、YOLO-World	短语定位与实时两条路线的代表，均有公开代码	零样本直接使用；在基础类上微调后使用
遥感开放词汇	CastDet、LAE-DINO、OpenRSD	分别代表伪标签、自动标注扩数据和多任务头三种遥感适配思路	优先使用官方代码与权重，在相同划分上复现
校准基线	温度缩放、Platt 缩放、保序回归	已有研究表明事后校准是强基线	施加在最强对照方法与本文方案之上

注：方法依据见文献[5,10,12,17-18,20-23]；OpenRSD 原文注明代码将会发布[20]，若实验开始时仍无法获取官方实现，则在结果表中注明缺失原因，不以自行复现的近似版本替代。

为保证比较公平，本文规定四条规则。其一，所有方法使用相同的数据划分、切片设置和评测脚本；对照方法若原本不支持切片，则统一接入本文的切片与融合模块，并同时报告“原始”和“接入切片后”两种结果。其二，所有方法的超参数搜索预算相同，以相同的验证集和相同的搜索次数为准。其三，查询文本对所有方法一致，本文的原型库不提供给对照方法，但会额外报告“对照方法加原型库”的结果，以区分原型库本身的作用与方案整体的作用。其四，原文报告的数值只作背景参考，不与本文复现的数值放在同一张表中比较，因为两者的划分和协议不同。

5.4 评价指标及其能支持的结论

一个指标只能支持特定类型的结论，用错指标会让实验回答错误的问题。例如，用新类 mAP 判断“结果能否直接使用”就是错位的，因为 mAP 只关心排序，不关心分数的绝对值。表 5-4 说明了每个指标测量什么、能支持什么判断，以及不能用它说明什么。

表 5-4 评价指标的测量对象与结论边界

指标	测量对象	能支持的结论	不能支持的结论
新类 mAP（IoU=0.5）	新类上的排序与定位综合质量	方案对新类的整体检测能力	分数是否可靠；属性理解是否正确
新类召回率（每图前 100 个候选）	新类目标是否被找到	原型适配与切片是否改善覆盖	结果能否直接采用
广义 mAP	基础类与新类混合时的表现	真实使用场景下的综合能力	新类与基础类各自的变化
旋转框 mAP	旋转框定位质量	几何协同的作用	语义匹配的质量
分组平均召回	按尺寸、长宽比分组的覆盖	H2 中收益集中于哪类目标	整体性能是否提高
D-ECE、Brier 分数	分数与正确率的一致程度	分数能否被解释为可靠程度	检测能力是否提高
高置信误报率	校准后高于 τ_h 的候选中误报的比例	“接受”状态是否安全	低分段的情况
风险—覆盖曲线	接受比例与误报率之间的权衡	三态决策在不同阈值下的表现	单一阈值下的最优点
查询一致性	同义查询下前 k 个候选的重合度	系统对用户措辞是否稳健	结果是否正确
中位数与第 99 百分位延迟	单图端到端耗时	是否满足交互式使用	离线批处理的吞吐量

注：指标定义的依据为通用检测评测惯例与校准文献[21-22]；在细粒度与属性查询上，本文参照 OVDEval 的建议额外计算 NMS-AP[24]，用于检验标准 AP 是否高估了属性理解能力。

其中三个指标的计算方式需要明确定义。检测期望校准误差按 Küppers 等人的做法[22]，把候选按可靠程度和框尺寸划分为若干单元 B_j，计算每个单元中平均可靠程度与实际正确率之差的加权平均：

$$\text{D-ECE} = \Sigma_j \left(|B_j| / N\right) \cdot \left| \text{acc}(B_j) - \text{conf}(B_j) \right| \tag{5-1}$$

其中 $acc(B_j)$ 为单元内与真值交并比不低于 0.5 的候选比例，$conf(B_j)$ 为单元内平均可靠程度，N 为候选总数。查询一致性衡量同一目标在不同问法下是否被找到。设查询 q 及其同义问法集合为 $S(q)$，$R_k(q)$ 为查询 q 下前 k 个候选所匹配的真值目标集合，则

$$\text{QC@k} = (1/|S(q)|) \cdot \Sigma_{q' \in S(q)} |R_k(q) \cap R_k(q')| / |R_k(q) \cup R_k(q')| \tag{5-2}$$

即各同义问法与标准问法所找到目标集合的平均交并比。风险—覆盖曲线以覆盖率（被接受的候选占全部候选的比例）为横轴、被接受候选中的误报率为纵轴，曲线越低越好；本文报告曲线下面积，并给出覆盖率为 50% 时的误报率作为单点参照。

指标之间存在冲突时，本文按预先规定的优先级解释结果：对 H1 以新类召回为主、新类 mAP 为辅；对 H3 以风险—覆盖曲线为主、D-ECE 为辅。之所以不以 D-ECE 为主，是因为已有研究指出它在特定评测框架下可能导致错误结论[23]。

5.5 主实验设计

主实验 E1 在 DIOR 和 DOTA-v1.0 划分上比较本文方案与表 5-3 中的所有对照方法。每个方法以 3 个随机种子运行，报告均值和 95% 置信区间。

主实验结果的解读规则是预先确定的。若本文方案的新类召回高于最强对照方法，且差值的 95% 置信区间不含 0，则认为 E1 支持 H1；若新类 mAP 提高但新类召回没有提高，说明收益来自排序而非覆盖，需要转而用 A2 和 A4 判断收益来源；若广义 mAP 下降，说明开放词汇改造损害了基础类能力，需要报告下降幅度并在第 7 章讨论。

延迟测试在固定硬件上进行，分别报告离线批处理（整图全部切片）和交互式查询（先低分辨率后细化）两种模式。延迟只在 E1 中报告，不作为方案优劣的主要依据，但若交互模式下第 99 百分位延迟超过使用方给定的上限，方案需要相应调整切片策略。

主结果按数据集分表报告。DIOR 划分采用水平框评测，结果表的格式见表 5-5；DOTA-v1.0 划分采用旋转框评测，表格结构相同，但以旋转框 mAP 替换基础类 mAP 一列，并增加小目标平均召回一列，以便与 E3 的分组分析衔接。两张表中的新类召回都按 5.2.2 节的“有先验”和“无先验”两组分别给出，读者因此可以直接看到收益是否只集中在预训练语料中常见的类别上。若某一对照方法只在一个数据集上可以运行，例如只支持水平框输出，则它只出现在对应的表中，并在表注中说明缺失原因。表 5-5 给出了 DIOR 划分主结果表的格式，结果待实测。

表 5-5 主实验结果表格式（DIOR 划分）

方法	设置	新类 mAP	新类召回	基础类 mAP	广义 mAP	D-ECE
Oriented R-CNN	闭集上界	待实测	待实测	待实测	待实测	待实测
Grounding DINO	零样本	待实测	待实测	待实测	待实测	待实测
Grounding DINO	基础类微调	待实测	待实测	待实测	待实测	待实测
YOLO-World	基础类微调	待实测	待实测	待实测	待实测	待实测
CastDet	官方实现	待实测	待实测	待实测	待实测	待实测
LAE-DINO	官方实现	待实测	待实测	待实测	待实测	待实测
本文方法	完整方案	待实测	待实测	待实测	待实测	待实测

注：表格结构依据 5.5 节的主实验设计；所有数值待实测，单位为百分比；结果以“均值 ± 95% 置信区间”报告，置信区间按影像重采样计算；延迟在固定硬件上单独报告；无法获取官方实现的方法在对应行注明原因，不填入估计值。

校准实验 E2 单独设计，因为它要回答的问题与 E1 不同：E1 比较方法，E2 比较同一方法上不同校准器的效果，以及校准能否从基础类外推到新类。表 5-6 列出了 E2 的实验设置。每种设置都施加在两个候选生成器上，即本文方案的候选层和 E1 中表现最好的对照方法，以检验校准结论是否依赖特定的候选生成器。

表 5-6 校准实验 E2 的设置

设置	校准集组成	校准器	是否分组	回答的问题
C0	不校准	无	否	原始分数的校准程度基线
C1	基础类与新类	温度缩放、Platt 缩放、保序回归	否	三种校准器的相对效果
C2	基础类与新类	同 C1	按目标尺寸分组	条件校准是否改善小目标
C3	仅基础类	同 C1	否	校准能否外推到新类
C4	仅基础类	同 C1	按目标尺寸分组	外推设置下条件校准的作用

注：设置依据为 4.5.2 节的校准方法与 2.5 节的校准文献[21-23]；各设置均为待实测项；校准集与测试集在影像层面互不重叠；设置 C3 与 C1 的差异用于度量 5.2.2 节所述“少量新类样本用于校准”带来的增益。

E2 的主要结论来自 C1 与 C3 的对比。若 C3 下新类的校准误差与 C1 相近，说明基础类上拟合的校准器可以外推到新类，三态决策在完全没有新类样本时也可使用；若 C3 明显变差，说明部署到新场景时需要先收集少量新类样本用于校准，这一结论会写入第 6 章的部署要求。

5.6 消融实验

消融实验从一个开放词汇基线出发，逐个加入模块，以便把 E1 中的整体收益归因到具体设计。加入的顺序遵循数据流方向，先处理候选覆盖，再处理语义，最后处理几何与可靠性，这样每一步新增的模块都建立在前一步已经检验过的输入之上。

除了按顺序加入，本文还做两组反向消融：从完整方案 A4 中分别单独去掉原型、旋转协同和校准，观察性能下降是否与正向加入时的提升一致。若两种方式给出的模块贡献相差很大，说明模块之间存在交互作用，此时报告交互效应，不给出单一的“贡献比例”。

原型模块内部还有三组细粒度消融：只用对象层原型、对象层加属性与场景层、三层原型加负向描述。这组实验回答一个具体问题：负向描述是否真的降低了背景误报，还是只是整体压低了分数。判定方法是比较高置信误报率与新类召回的同时变化，若两者同步下降，说明负向描述只是让分数整体变低。表 5-7 列出了正向消融的顺序和每一步要观察的指标。

表 5-7 消融实验设计

编号	配置	相对上一步新增的内容	观察指标	检验的假设
A0	开放词汇基线：类名作为文本输入，整图缩放，原始分数	无	全部主指标	基线参照
A1	A0 + 多尺度重叠切片与跨切片融合	切片与融合	新类召回、小目标平均召回、每图候选数	H2 的前提
A2	A1 + 三层原型与负向描述	语义适配	新类召回、跨域差值	H1
A3	A2 + 水平框与旋转框协同	几何协同	旋转框 mAP、分组平均召回	H2
A4	A3 + 证据分解、事后校准与三态决策	可靠性模块	D-ECE、Brier 分数、高置信误报率	H3

注：配置依据为第 4 章的模块划分与表 3-2 的假设；各配置均为待实测项；每步保持其余设置不变，随机种子与 E1 相同。

5.7 鲁棒性与跨域测试

鲁棒性测试检验方案在四类条件变化下的表现。第一类是查询变化：对每个新类准备标准类名、同义词、上位词和属性短语四种问法，计算 5.4 节定义的查询一致性。第二类是目标几何变化：按目标面积分为小（小于 32×32 像素）、中、大三组，按长宽比分为小于 2、2 到 4、大于 4 三组，按角度分为 15° 间隔的六组。第三类是成

像条件变化：按 DIOR 原文提供的成像条件信息，在条件可区分时分组报告[2]。第四类是切片参数变化：在三种切片尺寸和三种重叠率的组合上运行，观察结论是否依赖特定参数。

表 5-8 汇总了鲁棒性测试的条件网格。为控制实验量，几何与成像条件的分组不单独重新运行模型，而是在 E1 的测试结果上按分组重新计算指标；只有查询变化和切片参数变化需要额外运行。

表 5-8 鲁棒性测试的条件网格

变化维度	水平设置	是否需要额外运行	主要指标	关注的失效形式
查询措辞	标准类名、同义词、上位词、属性短语	是	查询一致性、新类召回	候选随措辞转移到其他目标
目标尺寸	小（<32×32 像素）、中、大	否	分组平均召回	小目标召回显著低于其他组
长宽比	<2、2～4、>4	否	分组旋转框 mAP	细长目标定位退化
方向角	以 15° 为间隔分为 6 组	否	分组平均召回	特定角度区间召回偏低
切片参数	3 种尺寸 × 3 种重叠率	是	新类召回、每图候选数、延迟	结论只在特定参数下成立

注：分组依据为 1.3 节的共性挑战与 DOTA、DIOR 原文对数据特性的描述[1-2]，边界为本文预先设定；各项结果待实测。

跨域测试 E4 包括两个层次。跨区域测试按地理范围划分训练和测试影像，检验原型是否学到了区域纹理；跨数据集测试在 DIOR 上训练、在 DOTA-v2.0 的新增类别上测试，检验方案在标注规范和成像来源都变化时的表现。跨域测试的主要指标是同域与跨域之间的性能差值，而不是跨域上的绝对值，因为它直接对应 H1 的否证条件。

5.8 统计不确定性与多重比较

遥感检测结果的不确定性有多个来源：随机种子、测试影像的抽样以及切片位置。本文以影像为单位做自助法重采样计算置信区间，而不是以候选框为单位，因为同一影像内的候选高度相关，以候选为单位会严重低估方差。方法之间的比较采用配对自助法：在同一组重采样影像上同时计算两种方法的指标差值，以差值的 95% 置信区间判断是否存在差异。具体而言，设测试集有 M 幅影像，第 b 次重采样有放回地抽取 M 幅影像，计算方法 A 与方法 B 的指标差值 Δ_b，重复 B 次后取

$$\mathrm{CI}_{95} = [\, Q_{0.025}(\Delta_1,\ldots,\Delta_B),\ Q_{0.975}(\Delta_1,\ldots,\Delta_B) \,] \tag{5-3}$$

其中 Q_α 为经验分位数，本文取 $B=1000$。对于跨区域测试，重采样以地理区域为单位进行，因为同一区域内的影像在地物和成像条件上也高度相关。随机种子带来的方差与影像抽样带来的方差分开报告：先对每个种子分别计算置信区间，再报告三个种子之间的极差，使读者可以判断哪一种不确定性占主导。

本文同时比较多个方法、多个指标和多个分组，存在多重比较问题。对于预先在表 3-2 中指定的主要比较，即每项假设对应的一个主要指标，不做多重比较校正；对于探索性的分组分析，采用 Holm 方法控制族错误率，并在结果中明确标注“探索性”。

随机种子数量为 3，这是在计算预算和方差估计之间的折中。若某项主要比较在 3 个种子下的置信区间宽度超过差值本身，本文会把种子数增加到 5，并在报告中说明增加的原因和时间点，而不是只在结果不显著时才增加。第 3 章表 3-2 中“召回下降不超过 2 个百分点”的容差，来自对使用方复核成本的设定：若召回下降 2 个百分点，每 100 个新类目标中多漏检 2 个，本文假定使用方可以通过复核队列中的“复核”状态弥补这一损失；该容差可由使用方调整，但必须在实验开始前确定。

5.9 案例研究：同义查询下的一致性

除了统计指标，本文设计一个机场场景的案例研究，用于展示查询措辞变化时系统的行为。案例选取一幅机场影像，针对同一架飞机依次输入五种问法：标准类名“飞机”、上位词“航空器”、俗称“客机”、属性短语“白色的大型飞机”以及描述性短语“停在停机坪上的飞机”。对每种问法，记录前 5 个候选、各项证据分数、校准后的可靠程度和三态决策，并邀请复核人员在证据卡辅助下判断结果。

案例研究不替代统计实验，它的作用是让读者看到具体的失效形式。本文预期可能出现两类失效：一是俗称或属性短语下候选转移到其他目标，例如“白色的大型飞机”的候选被吸引到白色的航站楼屋顶；二是候选位置不变但分数大幅下降，导致状态从“接受”变为“复核”。前者说明原型对属性的门控不足，后者说明查询稳定性分数在发挥作用。案例中实际出现哪种情况，以实验结果为准。

案例研究的可复现性要求与主实验相同：影像编号、查询文本、原型库版本、模型版本和阈值都随案例一起记录。为避免挑选有利案例，本文规定案例影像在实验运行前从测试集中随机抽取，若抽到的影像中不含飞机，则按预先确定的顺序抽取下一幅。

图 5-1 示意了这一案例的记录方式：上方为五种问法，中间为每种问法下的候选框及其局部放大图，时间轴上的颜色表示该问法下的结果与标准类名结果是否一致，下方为复核人员查看证据卡、记录结论并导出回放的过程。

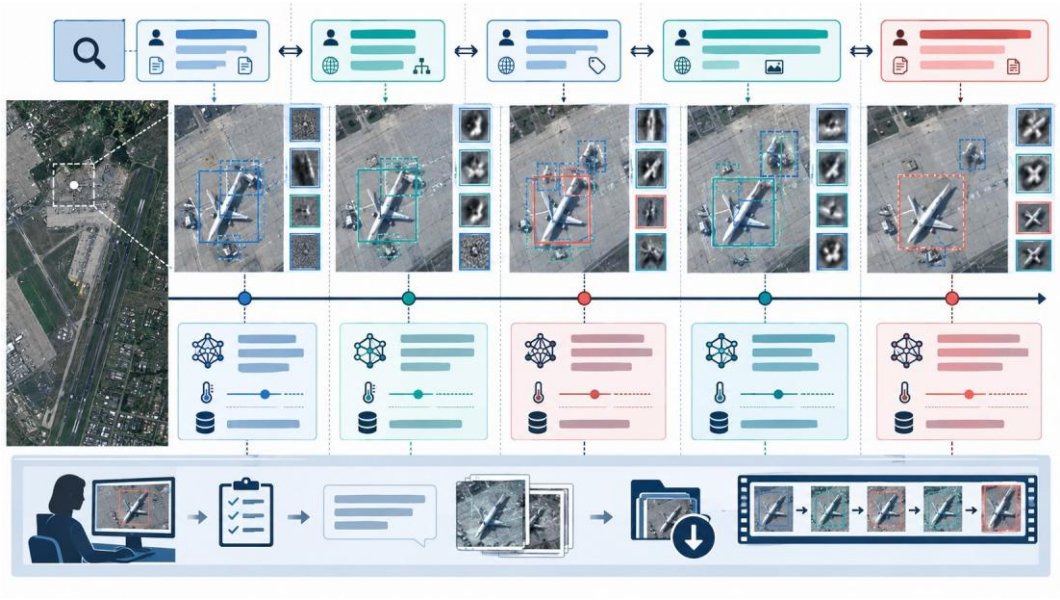


图 5-1 同义查询一致性案例的记录方式：五种问法下的候选与局部放大、问法间一致性标记、校准状态以及人工复核与回放（示意图，不代表实测结果）

5.10 失败分析与停止规则

失败分析从 E1 和 E4 的错误结果中抽样，按四类原因人工标注：候选缺失（目标没有任何候选覆盖）、定位错误（候选覆盖但交并比不足）、语义混淆（候选位置正确但被匹配到其他查询）和背景误报（候选落在背景上且分数较高）。每类原因再按目标尺寸和是否属于“无先验新类”细分。这一分析回答的是“方案在什么条件下失效”，其结论会写入第 7 章的研究局限。

本文预先规定了三条停止规则，用于在负面结果出现时决定研究方向，而不是继续堆叠模块。若 A2 的原型适配在所有跨区域测试中都没有带来收益，则停止扩充原型描述，转而检查投影层是否过拟合基础类。若 A3 的旋转协同只增加计算量，而旋转框 mAP 和小目标召回都没有改善，则把水平框作为默认输出，旋转框仅作为可选项。若 A4 的校准降低了误报，但新类召回下降超过预设容差，则不删除校准模块，而是把更多候选划入“复核”状态，并报告这一设置下的复核工作量。

所有负面结果都会写入最终报告，并保留对应的配置、日志和错误样例，本文不会只报告支持假设的实验。实验按表 5-9 的顺序执行，每一阶段的产出是下一阶段的输入，任何阶段的结果都不会因为后续阶段的发现而被回头修改。

表 5-9 实验执行顺序与阶段产出

阶段	内容	输入	产出	进入下一阶段的条件
一	数据去重、划分与新类先验统计	原始数据集	划分清单、去重日志、先验分组	划分清单冻结并公开
二	对照方法复现	划分清单	对照方法在验证集上的结果	复现结果与原文趋势一致，或差异原因已记录
三	原型库构建与超参数选择	验证集	冻结的原型库版本与超参数	冻结记录写入实验日志
四	主实验 E1 与消融 A0—A4	冻结的配置	主结果表与消融表	全部配置运行完毕
五	校准实验 E2 与几何分组 E3	阶段四的候选	校准结果与分组结果	三态阈值冻结
六	跨域测试 E4 与鲁棒性测试	冻结的全部设置	跨域差值与鲁棒性网格结果	全部条件运行完毕
七	人工复核实验 E5 与案例研究	阶段四的候选与阶段五的阈值	复核时间、一致性与案例记录	—

注：执行顺序的依据为 5.2 节的泄漏控制规则（先冻结再测试）；“复现结果与原文趋势一致”指在原文报告过的数据集上，复现结果的相对排序与原文一致，不要求数值相同。

第 6 章 系统实现与应用场景

6.1 系统组成与数据流

系统实现按第 4 章的五层框架组织为五个服务：切片服务负责读取影像、按配置生成多尺度切片并记录每个切片在整图中的坐标；编码服务加载视觉—语言骨干和原型库，对切片与查询分别编码，并缓存原型向量；候选服务调用候选生成器、计算四项证据并完成跨切片融合；决策服务加载冻结的校准器和三态阈值，为每个候选给出状态；记录服务把结果写入证据库，并向前端提供查询和回放接口。

服务之间以结构化记录传递数据。每条候选记录包含整图坐标下的候选框、框类型、来源切片编号、四项证据分数、校准后的可靠程度、状态、拒识原因和冲突类型；每次查询记录包含原始查询文本、规范化后的对象词、属性词和场景词、原型库版本、模型版本和校准器版本。这一设计使任意一个结果都可以追溯到产生它的全部输入，也使第 5 章的实验与系统运行使用同一套代码路径，避免“实验代码”和“演示代码”出现差异。

每个服务都规定了失败时的行为，原则是宁可显式失败，也不输出看似正常的错误结果。切片服务读到影像元数据缺失时拒绝处理，而不是假定一个分辨率；编码服务发现原型库版本与校准器版本不匹配时停止运行，因为校准器是在特定原型库版本上拟合的，混用会让可靠程度失去意义；候选服务在某个切片推理失败时，在结果中标记该切片区域为“未覆盖”，而不是静默跳过，使用者因此能区分“该区域没有目标”和“该区域没有被检测”；决策服务在校准器文件缺失时把全部候选置为复核状态。这些规则看似保守，但它们保证了一个结果要么带着完整的证据，要么明确标出缺失之处。

在数据流上，系统支持两种运行方式。离线批处理一次处理整幅影像的全部切片，适用于定期巡查和灾后普查；交互式查询先在低分辨率尺度上快速生成候选，用户在感兴趣的区域放大后，再在原始分辨率上细化。两种方式共享同一套原型库和校准器，区别只在于切片调度顺序。

6.2 证据卡与人工复核

证据卡是系统与复核人员之间的接口，它的设计目标是让复核人员在不了解模型内部的情况下判断一个候选是否可信。表 6-1 列出了证据卡的字段、每个字段帮助回答的问题以及缺失时的处理方式。

表 6-1 证据卡字段及其作用

字段	内容	帮助复核人员回答的问题	缺失时的处理
局部影像	候选区域及其周边一倍范围的原始分辨率影像	目标看起来是什么	不允许缺失，缺失则候选不展示
候选框	水平框或旋转框，标注是否“旋转不确定”	框是否准确覆盖目标	不允许缺失
四项证据	语义、几何、背景对照、查询稳定性分数及其相对高低	系统为什么认为是或不是目标	缺项以“未计算”标示，不填默认值
最相似原型	匹配到的对象、属性、场景原型及最接近的负向原型	有没有更合理的其他解释	显示“无负向原型”而非留空
可靠程度与状态	校准后的可靠程度、状态及所用阈值	这个结果在当前设定下的风险有多大	不允许缺失
冲突记录	语义、几何或来源冲突的类型与对方候选	是否存在细粒度类别混淆	无冲突时显示“无”
版本信息	原型库、模型、校准器版本与查询时间	结果能否复现	不允许缺失

注：字段设计依据为式 (3-1) 的证据分解与表 4-1 的三态决策；字段对复核时间的影响由实验 E5 检验，结果待实测。

人工复核的结论会回写到证据库，形成三类可利用的反馈：被复核为正确的“复核”状态候选，用于检查阈值是否过于保守；被复核为错误的“接受”状态候选，用于估计实际误报率并触发校准器的重新检查；反复出现的拒识原因，用于补充原型库中的负向描述。所有反馈只用于下一个版本的开发，不回写到当前版本的测试结果中，以免造成调参泄漏。

实验 E5 用于检验证据卡的实际作用。实验从 E1 测试集中抽取一定数量的候选，分为两组：一组只展示局部影像和候选框，另一组展示完整证据卡；复核人员在两种条件下交替工作，记录每个候选的复核时间和结论。复核者间一致性用 Cohen κ 系数衡量。为控制学习效应，两种条件的顺序在复核人员之间平衡。

6.3 应用场景与用户任务

本方案面向灾后快速评估、自然资源巡查和港口与交通监测三类用户场景。三类场景的共同点是查询对象经常超出固定类别表，结果最终都需要人工确认；不同点在于对漏检和误报的容忍程度、对响应时间的要求以及对细粒度区分的需要。表 6-2 列出了各场景的典型查询、对系统的主要要求以及对应的评测指标。

表 6-2 应用场景、典型查询与对应指标

场景	典型查询	对系统的主要要求	对应评测指标
灾后快速评估	受损建筑、临时帐篷、阻断道路的倒塌物	新类召回高，能在数小时内给出候选	新类召回、交互式延迟
自然资源巡查	采砂场、违规堆土、新增建筑	误报率低，结果可留档	高置信误报率、证据卡完整率
港口与交通监测	集装箱船、散货船、特定型号飞机	细粒度区分，旋转框定位准确	FAIR1M 细粒度新类 mAP、旋转框 mAP

注：场景依据为 1.1 节所述业务需求，场景与查询为本文设计的使用情境示例，不代表已部署或已获得的用户反馈；各指标的结果待实测。

三类场景对“接受”和“复核”的平衡要求不同。灾后评估更怕漏检，因此可以设定较低的 τ_h，把更多候选放入“接受”状态，再通过抽检控制质量；自然资源巡查的结果可能用于行政处理，更怕误报，因此需要较高的 τ_h，宁可让更多候选进入复核。系统允许使用方按场景设定风险水平，但每次设定都会记录在查询记录中，确保同一份结果可以追溯到当时的风险设定。

6.4 部署形态与成本边界

系统设计了三种部署形态。服务器端部署处理大幅影像的离线批处理，适合有固定计算资源的机构；工作站部署支持单人交互式查询，适合解译人员日常使用；边缘部署只运行轻量的候选生成器和已缓存的原型，把复杂的融合与校准交给服务器，适合现场快速查看。三种形态共享同一套原型库和校准器文件。

部署成本主要由切片数量和候选生成器决定。4.6 节的分析表明，单幅大图的切片数可能达到百个以上，若使用基于 Transformer 的候选生成器，离线处理一幅大图的耗时可能以分钟计。若交互式查询的延迟无法满足需求，可选的调整有三种：用更轻量的候选生成器替换，减少尺度数，或者只在用户选定的区域内运行原始分辨率切片。每种调整都会改变检测性能，因此第 5 章的延迟测试同时报告调整前后的主指标变化。

部署到新场景时还有一项不可省略的准备工作：校准。实验 E2 的设置 C3 会回答基础类上拟合的校准器能否外推到新类；在这一问题得到回答之前，本文建议在每个新场景中先人工标注少量样本，用于检查校准器的适用性。若检查显示校准误差明显增大，应当在新场景数据上重新拟合校准器，并重新确定三态阈值。需要明确的是，本文没有在真实业务环境中部署和测试本方案，上述部署形态和成本分析是基于模块结构的推断，实际成本需要在第 5 章的实验中按固定硬件实测。

6.5 风险、许可与数据治理

开放词汇检测降低了查询新目标的门槛，也带来相应的风险。第一，系统可能被用于查询涉及个人隐私或敏感设施的目标。本文在使用约定中限制查询范围，并在查询记录中保留查询人和查询时间，以便事后审计。第二，系统输出可能被误当作确定结论使用。三态决策和证据卡的设计目的之一，就是让使用者看到每个结果的可靠程度，避免把模型输出直接作为执法或定级依据。

数据和模型的使用遵循各自的许可条款。DIOR、DOTA、FAIR1M 等数据集仅用于研究和竞赛评测；对照方法的代码按其开源许可使用，其中部分实现采用 GPL（GNU 通用公共许可证）等具有传染性的许可，本文在系统中以独立进程调用这些实现，不将其代码合并到本文实现中。正式提交前，需要由负责人逐项核对数据集和代码许可的最新版本。

第 7 章 结论与研究局限

7.1 主要结论

本文围绕光学遥感影像中的开放词汇目标检测，提出了 OpenRSI-Calibrator 方案（第 4 章）及其评测设计（第 5 章）。由于第 5 章的实验尚未运行，本文的结论是设计层面的判断，而不是实证结论。

第一，文献分析表明，遥感开放词汇检测已有工作分别处理了语义偏移、实时性和旋转框输出，但对分数可靠性和查询措辞稳定性缺少系统评测。这一判断基于对 24 篇文献的梳理，其中关于域偏移的依据最为直接[18]，关于校准方法选择的依据来自通用检测领域[23]，其在遥感开放词汇设定下是否成立有待本文实验检验。

第二，本文把语义适配、几何协同和可靠性校准放在同一框架内，并通过分层接口使三者可以独立消融。这一设计的价值不在于任何单一模块的新颖性，而在于它使第 5 章的实验能够回答“收益来自哪里”和“在什么条件下失效”。

第三，本文把研究主张写成四项带有否证条件的假设，并在运行实验之前固定了数据划分、指标优先级、统计方法和停止规则。无论实验结果支持还是否证这些假设，都能得到可解释的结论。

7.2 研究局限

本文存在以下局限。其一，所有性能主张都尚未经过实验检验，第 5 章的结果表全部为待实测；若 H1 至 H3 被否证，第 4 章的设计需要相应调整。其二，原型库的质量依赖描述的写法，本文虽然规定了来源优先级和版本管理，但没有给出自动评价描述质量的方法。其三，预训练语料泄漏无法完全消除，本文只能通过“有先验”与“无先验”分组来度量其影响。其四，三态阈值依赖使用方给定的风险水平，本文没有研究如何在缺乏历史数据的新场景中设定这一水平。其五，本文只研究光学影像，结论不能直接推广到合成孔径雷达或多光谱影像。

7.3 后续工作

后续工作按优先级排列如下：首先完成第 5 章的主实验和消融实验，并依据停止规则调整方案；其次把原型库的构建从人工撰写扩展到从遥感图文语料中自动抽取候选描述，再经人工审核；最后在获得真实使用数据后，研究三态阈值的在线更新方法，以及在多光谱影像上的迁移可能。

参考文献

[1] XIA GS, BAI X, DING J, et al. DOTA: A Large-scale Dataset for Object Detection in Aerial Images[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018. https://arxiv.org/abs/1711.10398

[2] LI K, WAN G, CHENG G, et al. Object Detection in Optical Remote Sensing Images: A Survey and A New Benchmark[EB/OL]. (2019-08-31). https://arxiv.org/abs/1909.00133

[3] SUN X, WANG P, YAN Z, et al. FAIR1M: A Benchmark Dataset for Fine-grained Object Recognition in High-Resolution Remote Sensing Imagery[EB/OL]. (2021-03-09). https://arxiv.org/abs/2103.05569

[4] DING J, XUE N, XIA GS, et al. Object Detection in Aerial Images: A Large-Scale Benchmark and Challenges[EB/OL]. (2021-02-24). https://arxiv.org/abs/2102.12219

[5] XIE X, CHENG G, WANG J, et al. Oriented R-CNN for Object Detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2021. https://arxiv.org/abs/2108.05699

[6] GU X, LIN TY, KUO W, et al. Open-vocabulary Object Detection via Vision and Language Knowledge Distillation[C]//International Conference on Learning Representations (ICLR), 2022. https://arxiv.org/abs/2104.13921

[7] ZHONG Y, YANG J, ZHANG P, et al. RegionCLIP: Region-based Language-Image Pretraining[EB/OL]. (2021-12-16). https://arxiv.org/abs/2112.09106

[8] ZHOU X, GIRDHAR R, JOULIN A, et al. Detecting Twenty-thousand Classes using Image-level Supervision[C]//European Conference on Computer Vision (ECCV), 2022. https://arxiv.org/abs/2201.02605

[9] LI LH, ZHANG P, ZHANG H, et al. Grounded Language-Image Pre-training[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022. https://arxiv.org/abs/2112.03857

[10] LIU S, ZENG Z, REN T, et al. Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection[EB/OL]. (2023-03-09). https://arxiv.org/abs/2303.05499

[11] MINDERER M, GRITSENKO A, STONE A, et al. Simple Open-Vocabulary Object Detection with Vision Transformers[C]//European Conference on Computer Vision (ECCV), 2022. https://arxiv.org/abs/2205.06230

[12] CHENG T, SONG L, GE Y, et al. YOLO-World: Real-Time Open-Vocabulary Object Detection[EB/OL]. (2024-01-30). https://arxiv.org/abs/2401.17270

[13] LIU F, CHEN D, GUAN Z, et al. RemoteCLIP: A Vision Language Foundation Model for Remote Sensing[EB/OL]. (2023-06-19). https://arxiv.org/abs/2306.11029

[14] ZHANG Z, ZHAO T, GUO Y, et al. RS5M and GeoRSCLIP: A Large Scale Vision-Language Dataset and A Large Vision-Language Model for Remote Sensing[EB/OL]. (2023-06-20). https://arxiv.org/abs/2306.11300

[15] WANG Z, PRABHA R, HUANG T, et al. SkyScript: A Large and Semantically Diverse Vision-Language Dataset for Remote Sensing[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2024. https://arxiv.org/abs/2312.12856

[16] ZANG Z, LIN C, TANG C, et al. Zero-Shot Aerial Object Detection with Visual Description Regularization[EB/OL]. (2024-02-28). https://arxiv.org/abs/2402.18233

[17] LI Y, GUO W, YANG X, et al. Toward Open Vocabulary Aerial Object Detection with CLIP-Activated Student-Teacher Learning[C]//European Conference on Computer Vision (ECCV), 2024. https://arxiv.org/abs/2311.11646

[18] PAN J, LIU Y, FU Y, et al. Locate Anything on Earth: Advancing Open-Vocabulary Object Detection for Remote Sensing Community[EB/OL]. (2024-08-17). https://arxiv.org/abs/2408.09110

[19] WEI G, YUAN X, LIU Y, et al. RT-OVAD: Real-Time Open-Vocabulary Aerial Object Detection via Image-Text Collaboration[EB/OL]. (2024-08-22). https://arxiv.org/abs/2408.12246

[20] HUANG Z, FENG Y, YANG S, et al. OpenRSD: Towards Open-prompts for Object Detection in Remote Sensing Images[EB/OL]. (2025-03-08). https://arxiv.org/abs/2503.06146

[21] GUO C, PLEISS G, SUN Y, et al. On Calibration of Modern Neural Networks[C]//International Conference on Machine Learning (ICML), 2017. https://arxiv.org/abs/1706.04599

[22] KÜPPERS F, KRONENBERGER J, SHANTIA A, et al. Multivariate Confidence Calibration for Object Detection[EB/OL]. (2020-04-28). https://arxiv.org/abs/2004.13546

[23] KUZUCU S, OKSUZ K, SADEGHI J, et al. On Calibration of Object Detectors: Pitfalls, Evaluation and Baselines[EB/OL]. (2024-05-30). https://arxiv.org/abs/2405.20459

[24] YAO Y, LIU P, ZHAO T, et al. How to Evaluate the Generalization of Detection? A Benchmark for Comprehensive Open-Vocabulary Detection[EB/OL]. (2023-08-25). https://arxiv.org/abs/2308.13177